มหาวิทยาลัยเทคโนโลยีพระจอมเกล้าธนบุรี

สถาบันวิทยาการหุ่นยนต์ภาคสนาม

รายงานการทดลอง

Lab 3 State Estimation

วิชา FRA233 Control Engineering for Robotics

จัดทำโดย

นายทัดชัย สุขสราญ	67340500016
นายธนดล พูลสระคู	67340500017
นายธรรวิทวัส เพ็งนาม	67340500018
นายวราวิชญ์ ศิลายงค์	67340500036
นายภคิน ศักดิ์สิทธิ์พิทักษ์	67340500060
นางสาวศิรินภา สุขบุญส่ง	67340500078

ปีการศึกษา 2568

1. การทดลองที่ 1: วัดค่า Spring Constant (K)

ครอบคลุม Criteria: Part 1 System Modeling — ออกแบบการทดลองหา K, รายงานค่าทางสถิติ (รวม 2 คะแนน)

1.1 บทนำ

ในการสร้างแบบจำลองทางคณิตศาสตร์ของระบบ Mass-Spring-Damper นั้น ค่า Spring Constant หรือ K คือพารามิเตอร์พื้นฐานตัวแรกที่จำเป็นต้องทราบ โดย K คือค่าที่บอกว่าสปริงต้านทานแรงได้มากน้อยเพียงใดต่อหนึ่งหน่วยของการกระจัด ซึ่งอธิบายได้ด้วย Hooke's Law ในรูป $F = Kx$ ค่านี้จะถูกนำไปใช้โดยตรงในการสร้าง State-Space Model และ Equation of Motion ของระบบในการทดลองที่ 4 และ 5 ดังนั้นความแม่นยำของ K จึงส่งผลโดยตรงต่อความถูกต้องของ Kalman Filter ที่จะสร้างขึ้นในภายหลัง

การหาค่า K ทำได้โดยอาศัยหลักการของ Hooke's Law ซึ่งระบุว่าในช่วง Linear Elastic ของสปริง แรงที่กระทำต่อสปริง F จะแปรผันตรงกับระยะที่สปริงยืดหรือหดออกจากตำแหน่งปกติ x โดย K คือความชันของความสัมพันธ์นี้ ในทางปฏิบัติการทดลองนี้จะทำโดยการใส่มวลที่รู้ค่าลงบนสปริงทีละขั้น แล้ววัดระยะกระจัดที่เกิดขึ้นในแต่ละน้ำหนัก จากนั้นนำข้อมูลที่ได้มา Plot กราฟ Force vs. Displacement และใช้ Linear Regression หาค่า K จาก Slope ของเส้นตรงที่ได้

อย่างไรก็ตาม ในการรายงานค่า K อย่างน่าเชื่อถือนั้น การวัดเพียงครั้งเดียวไม่เพียงพอ เนื่องจากการทดลองในโลกความเป็นจริงย่อมมีความคลาดเคลื่อนเกิดขึ้นเสมอ ไม่ว่าจะมาจากความไม่สม่ำเสมอของสปริงเอง การอ่านค่าของผู้ทดลอง หรือสปริงที่อาจไม่ได้ตั้งตรงแนวดิ่งอย่างสมบูรณ์ ดังนั้นการทดลองนี้จึงกำหนดให้ทำซ้ำหลายครั้งและใช้วิธีการทางสถิติที่เหมาะสม เช่น ค่าเฉลี่ย ส่วนเบี่ยงเบนมาตรฐาน และค่า R^2 ในการประเมินความน่าเชื่อถือของผลลัพธ์ที่ได้

1.2 วัตถุประสงค์

- เพื่อหาค่า Spring Constant K ของสปริงที่ใช้ในชุดทดลอง Mass-Spring-Damper
- เพื่อเลือกและใช้วิธีทางสถิติที่เหมาะสมในการรายงานค่า K อย่างน่าเชื่อถือ
- เพื่อยืนยันว่าสปริงทำงานในช่วง Linear Elastic ตาม Hooke's Law

1.3 สมมติฐาน

- ความสัมพันธ์ระหว่างแรงและการกระจัดของสปริงจะเป็นเชิงเส้น (Linear) ในช่วงน้ำหนักที่ทดสอบ
- ค่า K ที่ได้จาก Linear Regression จะมีความสม่ำเสมอและค่า R^2 สูง

1.4 ตัวแปร

1. **ตัวแปรต้น (Independent Variable):** มวลที่กระทำต่อสปริง โดยทำการเพิ่มน็อตตัวเมียทีละ 1 ตัว น้ำหนักประมาณตัวละ 38 g (เพิ่มได้สูงสุด 5 ตัว รวมน้ำหนักสูงสุด 190 g)
2. **ตัวแปรตาม (Dependent Variable):** ระยะการกระจัด x (m) ที่เกิดขึ้นในแต่ละระดับน้ำหนัก
3. **ตัวแปรควบคุม (Control Variables):**
    - ชนิดและค่าความแข็งเดิมของสปริงที่ใช้ทดสอบ

- อุณหภูมิห้องและสภาพแวดล้อม
- ทิศทางการแขวนสปริง (ต้องอยู่ในแนวดิ่งเสมอเพื่อป้องกันแรงเสียดทานด้านข้าง)
- ตำแหน่ง Reference เริ่มต้นก่อนทำการโหลดมวล

1.5 เอกสารและงานวิจัยที่เกี่ยวข้อง

1.5.1 กฎของฮุก (Hooke's Law) และข้อสมมติของวัสดุยืดหยุ่นเชิงเส้น

ความหมายและความสำคัญของกฎของฮุก กฎของฮุกเป็นทฤษฎีพื้นฐานทางกลศาสตร์วัสดุที่ใช้อธิบายความสัมพันธ์ระหว่างแรงที่กระทำต่อวัสดุกับการเปลี่ยนรูปที่เกิดขึ้น โดย Robert Hooke ได้เสนอหลักการนี้ในปี ค.ศ. 1678 ซึ่งระบุว่า:

- ภายในช่วงยืดหยุ่นของวัสดุ (Elastic Region) การเปลี่ยนรูปของวัสดุจะแปรผันตรงกับแรงที่กระทำ
- เมื่อแรงที่กระทำเพิ่มขึ้น การยืดตัวหรือการเสียรูปของวัสดุจะเพิ่มขึ้นตามสัดส่วนเดียวกัน
- ตราบใดที่วัสดุยังไม่เกินขีดจำกัดการยืดหยุ่น (Elastic Limit) ความสัมพันธ์นี้ยังคงมีผลบังคับใช้

ความสัมพันธ์ระหว่างความเค้นและความเครียด ความสัมพันธ์ดังกล่าวสามารถอธิบายได้ผ่านสมการทางคณิตศาสตร์ดังนี้

$$\sigma = E\varepsilon \tag{1}$$

โดยที่:

- σ คือความเค้น (Stress) แรงที่กระทำต่อพื้นที่หนึ่งหน่วย
- ε คือความเครียด (Strain) การเปลี่ยนแปลงรูปร่างสัมพัทธ์ของวัสดุ
- E คือมอดูลัสยัง (Young's Modulus) ตัวบ่งบอกความแข็งของวัสดุ

หากวัสดุมีค่า Young's Modulus สูง จะสามารถต้านทานการเปลี่ยนรูปได้มากกว่าวัสดุที่มีค่า Young's Modulus ต่ำ

การประยุกต์ใช้กฎของฮุกกับระบบสปริง สำหรับระบบสปริง กฎของฮุกสามารถอธิบายในรูปความสัมพันธ์ระหว่างแรงกับการกระจัด ดังสมการต่อไปนี้

$$F = Kx \tag{2}$$

โดยที่:

- F คือแรงที่กระทำ (หน่วย: นิวตัน)
- K คือค่าคงที่ของสปริง (Spring Constant) ตัวแสดงความแข็งของสปริง
- x คือระยะยืดตัว (Displacement)

สมการนี้แสดงให้เห็นว่า:

- การยืดตัวของสปริงมีความสัมพันธ์เชิงเส้นกับแรงที่กระทำ
- ค่าความชันของกราฟแรง-การกระจัดสามารถใช้แทนค่าคงที่ของสปริงได้

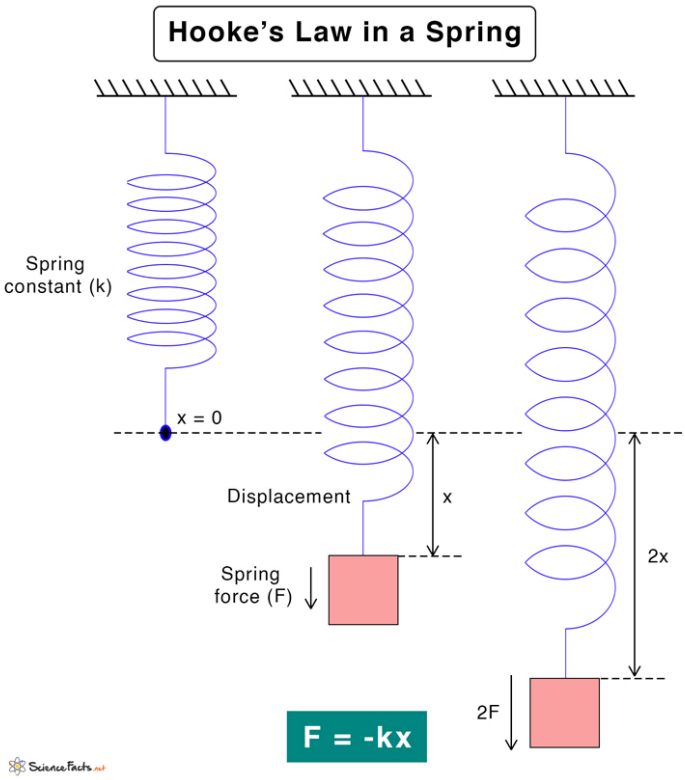

รูปที่ 1: แผนภาพแสดงกฎของฮุก (Hooke's Law)

1.5.2 ข้อสมมติของวัสดุยืดหยุ่นเชิงเส้น (Linear Elastic Assumptions)

- **ข้อสมมติที่ 1 ความสัมพันธ์เชิงเส้นระหว่างความเค้นและความเครียด:** วัสดุต้องมีความสัมพันธ์ระหว่างความเค้นและความเครียดเป็นเชิงเส้น และต้องเป็นไปตามกฎของฮุกอย่างสมบูรณ์ภายในช่วง Elastic Region เท่านั้น
- **ข้อสมมติที่ 2 สมมติการเปลี่ยนรูปเล็กน้อย (Small Deformation Assumption):** การเปลี่ยนรูปของวัสดุต้องมีขนาดเล็กจนสามารถละเลยผลของการเปลี่ยนแปลงทางเรขาคณิตได้
- **ข้อสมมติที่ 3 ความสามารถในการคืนรูป (Reversibility):** วัสดุต้องสามารถคืนรูปได้เมื่อยกเลิกแรงกระทำ ไม่เกิดการเสียรูปถาวร
- **ข้อสมมติที่ 4 สมบัติเชิงกลคงที่:** สมบัติเชิงกลของวัสดุ เช่น Young's Modulus และ Poisson's Ratio ต้องคงที่ตลอดช่วงการรับแรง
- **ข้อสมมติที่ 5 หลักการซ้อนทับ (Superposition Principle):** ผลตอบสนองรวมของระบบที่เกิดจากแรงหลายแรงสามารถหาได้จากผลรวมของผลตอบสนองที่เกิดจากแต่ละแรงแยกกัน

1.5.3 วิธีการทางสถิติ (Statistical Methods)

ค่าเฉลี่ย (Mean) ค่าเฉลี่ยเป็นตัวชี้วัดแนวโน้มเข้าสู่ส่วนกลางของข้อมูล ใช้แสดงค่าตัวแทนของชุดข้อมูลจากการวัดซ้ำ โดยคำนวณจากสมการ

$$\bar{x} = \frac{1}{N}\sum_{i=1}^{N} x_i \tag{3}$$

โดยที่ $\bar{x}$ คือค่าเฉลี่ย, x_i คือค่าข้อมูลแต่ละตัว, และ N คือจำนวนข้อมูลทั้งหมด

ส่วนเบี่ยงเบนมาตรฐาน (Standard Deviation) ส่วนเบี่ยงเบนมาตรฐานเป็นเครื่องมือที่ใช้วัดการกระจายตัวของข้อมูลจากค่าเฉลี่ย โดยคำนวณได้จากสมการ

$$s = \sqrt{\frac{\sum_{i=1}^{N}(x_i - \bar{x})^2}{N-1}} \tag{4}$$

สัมประสิทธิ์ความแปรปรวน (Coefficient of Variation: CV) สัมประสิทธิ์ความแปรปรวนเป็นอัตราส่วนระหว่างส่วนเบี่ยงเบนมาตรฐานกับค่าเฉลี่ย และแสดงในรูปเปอร์เซ็นต์

$$CV = \frac{s}{\bar{x}} \times 100\% \tag{5}$$

1.5.4 การวิเคราะห์การถดถอยเชิงเส้น (Linear Regression)

การวิเคราะห์การถดถอยเชิงเส้นเป็นเครื่องมือสำคัญในการศึกษาความสัมพันธ์ระหว่างตัวแปร สมการพื้นฐานของการถดถอยเชิงเส้นสามารถเขียนได้เป็น

$$y = mx + c \tag{6}$$

โดยที่ y คือตัวแปรตาม, x คือตัวแปรอิสระ, m คือความชัน (Slope), และ c คือจุดตัดแกน (Intercept)

สำหรับการทดลองที่เกี่ยวข้องกับกฎของฮุก เมื่อบังคับให้เส้นตรงผ่านจุดกำเนิด (Intercept = 0) สูตร Slope จาก Regression ผ่านจุดกำเนิดคือ

$$K = \frac{\sum_{i=1}^{n} F_i \cdot \Delta x_i}{\sum_{i=1}^{n} (\Delta x_i)^2} \tag{7}$$

สัมประสิทธิ์การตัดสินใจ (R^2) ค่า R^2 ใช้วัดระดับความสอดคล้องของข้อมูลกับเส้นแนวโน้ม หากค่า R^2 มีค่าเข้าใกล้ 1 (เช่น 0.95 ขึ้นไป) แสดงว่าข้อมูลมีความสัมพันธ์เชิงเส้นที่ดีและสอดคล้องกับแบบจำลองทางทฤษฎี

1.6 ขั้นตอนการทดลอง

1. ติดตั้งสปริงในแนวดิ่งกับชุดทดลอง จากนั้นกำหนดตำแหน่ง Reference โดยวัดระยะจากปลายสปริงถึงจุดอ้างอิงขณะยังไม่มีโหลดใดๆ บันทึกเป็น x_{ref}
2. ใส่น็อตตัวเมียทีละหนึ่งตัวจนครบ 5 ตัว เพราะน้ำหนักสูงสุดที่ใส่ได้คือ น็อต 5 ตัว โดยชั่งมวลน็อตแต่ละชุดสะสมก่อนทดลองเพื่อให้ทราบค่า m ที่แน่นอน แล้วคำนวณแรงกระทำที่แต่ละระดับโหลดด้วย

$$F = mg, \qquad g = 9.81 \text{ m/s}^2 \tag{8}$$

3. วัดระยะ x จากตำแหน่ง Reference ที่แต่ละระดับโหลด ทำซ้ำ 3 ครั้งต่อระดับโดยถอดและใส่โหลดใหม่ทุกครั้ง เพื่อหาค่าเฉลี่ยและลด Bias จากการอ่านค่าซ้ำในตำแหน่งเดิม บันทึกเป็น x_1, x_2, x_3 และคำนวณการกระจัดสุทธิ

$$\Delta x = \bar{x} - x_{\text{ref}} \tag{9}$$

4. Plot กราฟ F (แกน y) เทียบกับ Δx (แกน x) และ Fit เส้นตรงผ่านจุดกำเนิด (Intercept = 0) ด้วย Linear Regression เพื่อให้สอดคล้องกับ Hooke's Law: $F = K \cdot \Delta x$
5. อ่านค่า K จาก Slope ของ Regression Line คำนวณ Mean และ Standard Deviation ของ K_i จาก Point Estimate แต่ละจุด รวมถึงค่า R^2 เพื่อยืนยันความเป็นเชิงเส้น

$$K_i = \frac{F_i}{\Delta x_i}, \qquad \bar{K} = \frac{1}{n}\sum_{i=1}^{n} K_i, \qquad S.D.(K) = \sqrt{\frac{\sum(K_i - \bar{K})^2}{n-1}} \tag{10}$$

การเลือกใช้ 5 ระดับโหลด (6 จุดข้อมูลรวมจุดกำเนิด) เป็นจำนวนขั้นต่ำที่ทำให้ Linear Regression มีระดับความเป็นอิสระ (Degree of Freedom) เพียงพอสำหรับการประมาณค่า K และ Intercept พร้อมกันโดยไม่เกิด Overfitting อย่างไรก็ตาม หากเพิ่มจำนวนจุดข้อมูลมากขึ้น ค่า Slope ที่ได้จะมี Standard Error ลดลง ทำให้ค่า K มีความน่าเชื่อถือสูงขึ้น แต่ต้องแลกกับเวลาและความพยายามในการ ทดลองที่เพิ่มขึ้นด้วย

1.7 ผลการทดลอง

1.7.1 ตารางข้อมูลที่บันทึกได้

ตารางด้านล่างแสดงค่าแรงที่กระทำต่อสปริง ($F = mg$) และค่าการกระจัดเฉลี่ย ($\bar{x}$) พร้อมส่วนเบี่ยงเบนมาตรฐาน (S.D.) ที่ได้จากการวัด 3 ครั้งในแต่ละระดับโหลด โดยกำหนดตำแหน่ง Reference ที่ไม่มีโหลดเป็น $x_{\text{ref}} = 93.272$ mm และคำนวณการกระจัดสุทธิ $\Delta x = \bar{x} - x_{\text{ref}}$

1.7.2 การคำนวณค่า K ด้วย Linear Regression

จาก Hooke's Law ความสัมพันธ์ระหว่างแรงและการกระจัดอยู่ในรูป $F = K \cdot \Delta x$ ดังนั้น K คือความชันของเส้นตรง (Slope) ที่ได้จากการทำ Linear Regression ของข้อมูล Force vs. Displacement

ตารางที่ 1: ตารางสรุปผลการทดลองหาค่า Spring Constant (เฉพาะค่าเฉลี่ย)

มวลเฉลี่ย $\bar{m}$ (kg)	**แรง $F = mg$ (N)**	**ระยะเฉลี่ย $\bar{x}$ (m)**	**S.D. ของ x (mm)**	**S.D. ของ m (g)**
0.000	0.000	0.094	0.045	0.000
0.038	0.372	0.106	1.133	0.115
0.076	0.743	0.118	1.234	0.153
0.114	1.116	0.131	1.437	0.379
0.152	1.488	0.144	0.866	0.208
0.190	1.860	0.158	1.281	0.289

หมายเหตุ: ค่า $\bar{x}$ ในตารางนี้แสดงผลแบบ Round เพื่อความกระชับ ค่า Δx ที่ใช้คำนวณจริงในตารางที่ 2 คำนวณจากข้อมูลดิบก่อน Round ดังนั้นจึงมีทศนิยมมากกว่า

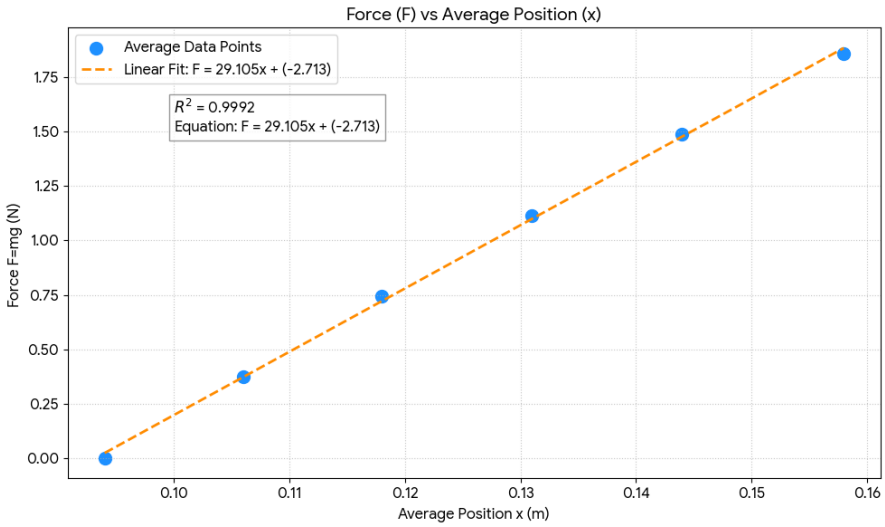

รูปที่ 2: กราฟแสดงผลการทดลองระหว่างแรงกับการกระจัด

ในการวิเคราะห์นี้ใช้สองแนวทาง ได้แก่ **(1) OLS ผ่านจุดกำเนิด** ซึ่งตรงกับนิยามของ Hooke's Law โดยตรง และ **(2) Full OLS with Intercept** ซึ่งอนุญาตให้มี Offset คงที่ เพื่อรองรับความคลาดเคลื่อนเชิงระบบของการตั้งค่าอุปกรณ์

แนวทางที่ 1: OLS ผ่านจุดกำเนิด บังคับให้ Intercept = 0 ตามนิยามของ Hooke's Law ($F = K \cdot \Delta x$) สูตรที่ใช้คือ

$$K_{\text{origin}} = \frac{\sum_{i=1}^{n}(F_i \cdot \Delta x_i)}{\sum_{i=1}^{n}(\Delta x_i)^2} = \frac{0.257951}{0.008746} \approx 29.49 \text{ N/m} \tag{11}$$

แนวทางที่ 2: Full OLS with Intercept (ค่าที่เลือกใช้) เมื่อ Plot กราฟ F vs. Δx พบว่าเส้น Regression ไม่ผ่านจุดกำเนิดพอดี แต่มี Offset เล็กน้อย ซึ่งสะท้อนถึง Systematic Error จากการกำหนด Reference Position (x_{ref}) ที่มี Measurement Noise เล็กน้อย จึงใช้ Full OLS ในรูป $F = K \cdot \Delta x + c$

เพื่อจัดการ Offset นี้

$$\boxed{K = 29.11 \text{ N/m}} \quad , \quad c = 0.0163 \text{ N} \tag{12}$$

ค่า $K = 29.11$ N/m นี้จะถูกนำไปใช้ในการทดลองที่ 4 และ 5 ทั้งหมด เนื่องจาก Full OLS ลด Bias จาก Systematic Offset ได้ดีกว่า OLS ผ่านจุดกำเนิด

1.8 ผลการวิเคราะห์ค่าคงที่สปริง (Spring Constant Analysis)

จากการทดลองหาความสัมพันธ์ระหว่างแรง F และระยะยืด Δx เพื่อหาค่าคงที่สปริง K ตามกฎของฮุก ($F = k\Delta x$) สามารถสรุปผลการวิเคราะห์เชิงสถิติได้ดังนี้

1.8.1 การวิเคราะห์ด้วยวิธีการถดถอยเชิงเส้น (Linear Regression)

จากการวิเคราะห์ใน Section 1.7.2 ด้วย Full OLS ได้ผลลัพธ์:

$$\boxed{K = 29.11 \text{ N/m}} \quad , \quad c = 0.0163 \text{ N} \tag{13}$$

เมื่อ c คือ Systematic Offset ของระบบการวัด ค่า $K = 29.11$ N/m ถูกเลือกเป็นค่าสุดท้ายเนื่องจาก Full OLS จัดการ Offset ได้ดีกว่า OLS ผ่านจุดกำเนิด (ซึ่งให้ $K_{\text{origin}} = 29.49$ N/m)

1.8.2 ค่าทางสถิติและจุดประมาณการ (Point Estimates)

เพื่อตรวจสอบความสม่ำเสมอของค่าคงที่สปริงในแต่ละช่วงน้ำหนัก จึงคำนวณค่า K_i ณ แต่ละระดับโหลดโดยใช้ความสัมพันธ์ $K_i = F_i/\Delta x_i$ ผลลัพธ์แสดงดังตารางที่ 2:

ตารางที่ 2: ค่า Point Estimate ของ K ที่แต่ละระดับโหลด

ระดับโหลด	F_i **(N)**	Δx_i **(m)**	K_i **(N/m)**
1	0.372	0.01222	30.44
2	0.743	0.02429	30.59
3	1.116	0.03735	29.88
4	1.488	0.05007	29.72
5	1.860	0.06407	29.03

จากการคำนวณหาค่าเฉลี่ย ($\bar{K}$) และค่าเบี่ยงเบนมาตรฐาน (S.D.) ของกลุ่มตัวอย่าง:

$$\bar{K} = \frac{\sum_{i=1}^{n} K_i}{n} = 29.93 \text{ N/m} \tag{14}$$

$$S.D.(K) = \sqrt{\frac{\sum_{i=1}^{n}(K_i - \bar{K})^2}{n-1}} \approx 0.63 \text{ N/m} \tag{15}$$

หมายเหตุ: ค่าเฉลี่ย 29.93 N/m มีค่าสูงกว่าค่าจากการถดถอยเชิงเส้นเล็กน้อย เนื่องจากการคำนวณรายจุดไม่ได้พิจารณาค่าความคลาดเคลื่อนคงที่ (c) ของเครื่องมือวัด

1.8.3 การคำนวณค่าสัมประสิทธิ์การตัดสินใจ (R^2)

เพื่อประเมินความแม่นยำของโมเดล $F = 29.11\Delta x + 0.0163$ จึงทำการคำนวณค่า R^2 สำหรับการถดถอยเชิงเส้น ดังนี้:

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}} = 1 - \frac{\sum_{i=1}^{n}(F_i - \hat{F}_i)^2}{\sum_{i=1}^{n}(F_i - \bar{F})^2} \tag{16}$$

โดยที่ $\hat{F}_i$ คือค่าแรงที่ทำนายจากสมการ และ $\bar{F} = 0.93$ N คือค่าเฉลี่ยของแรงทั้งหมด

ตารางที่ 3: ตารางคำนวณ Residuals สำหรับการตรวจสอบค่า R^2

i	Δx_i (m)	F_i (N)	$\hat{F}_i$ (N)	$(F_i - \hat{F}_i)^2$	$(F_i - \bar{F})^2$
1	0.00000	0.000	0.0163	0.000266	0.8643
2	0.01222	0.372	0.3721	0.000000	0.3060
3	0.02429	0.743	0.7234	0.000384	0.0347
4	0.03735	1.116	1.1034	0.000159	0.0360
5	0.05007	1.488	1.4740	0.000196	0.3117
6	0.06407	1.860	1.8814	0.000458	0.8655
Sum				**0.001463**	**2.4182**

แทนค่าเพื่อหาผลลัพธ์:

$$R^2 = 1 - \frac{0.001463}{2.4182} \approx 0.9994 \tag{17}$$

ค่า R^2 ที่เข้าใกล้ 1 ยืนยันว่าสมการเชิงเส้นนี้สามารถอธิบายพฤติกรรมของสปริงได้อย่างครอบคลุม

1.9 สรุปและอภิปรายผล

- **สรุปผล:** เลือกรายงานค่าคงที่สปริง $K = 29.11$ N/m จากวิธี Linear Regression เนื่องจากให้ค่า $R^2 = 0.9994$ ซึ่งแสดงถึงความแม่นยำสูง และสามารถจัดการกับค่า Offset ($c = 0.0163$ N) ของระบบได้ดีกว่าการหาค่าเฉลี่ยรายจุด
- **อภิปรายผล:** ความคลาดเคลื่อน (S.D. ≈ 0.63 N/m) ส่วนใหญ่เกิดจาก Measurement Noise ในการอ่านค่าระยะยืดด้วยสายตา อย่างไรก็ตาม ค่า K ที่ได้มีความเสถียรเพียงพอสำหรับการนำไปประยุกต์ใช้ใน State-Space Model
- **การนำไปใช้:** ค่า $K = 29.11$ N/m จะถูกนำไปบรรจุลงใน System Matrix ของ Kalman Filter เพื่อใช้ในการพยากรณ์สถานะ (State Prediction) ของระบบมวล-สปริงในการทดลองขั้นต่อไป

2. การทดลองที่ 2: สร้าง Library HC-SR04 และวัด Measurement Noise Covariance

ครอบคลุม Criteria: Part 2 — สร้าง Library HC-SR04, หาค่า R จาก Variance ของ Raw Data (ส่วนหนึ่งของ 5.5 คะแนน)

2.1 บทนำ

ในระบบควบคุมอัตโนมัติและหุ่นยนต์ ข้อมูลที่ได้รับจากเซนเซอร์มักมีสัญญาณรบกวน (Measurement Noise) แฝงอยู่เสมอ หากนำค่าดิบ (Raw Data) เหล่านี้ไปใช้งานโดยตรง อาจทำให้ระบบตอบสนองผิดพลาดหรือขาดเสถียรภาพได้ ก่อนที่จะออกแบบ Kalman Filter ใดๆ จำเป็นต้องทราบค่า Measurement Noise Covariance (R) ของเซนเซอร์ที่ใช้งานจริงก่อน เนื่องจาก R เป็นพารามิเตอร์ ที่บอกให้ Filter ทราบว่าควรเชื่อถือการวัดจาก Sensor มากน้อยเพียงใด

การทดลองนี้จึงมีเป้าหมายในการ (1) พัฒนา Library สำหรับอ่านค่าระยะทาง จาก HC-SR04 บน STM32 Nucleo G474RE และ (2) วัดค่า Measurement Noise Covariance ของเซนเซอร์ที่ระยะต่างๆ อย่างเป็นระบบ โดยใช้วิธีการทางสถิติ ที่เหมาะสม ผลลัพธ์ที่ได้จะนำไปใช้เป็นค่า R สำหรับ Kalman Filter ในการทดลองที่ 3 และ 5 ต่อไป

2.2 วัตถุประสงค์

- เพื่อพัฒนา Library hcsr04.c/hcsr04.h สำหรับอ่านค่า Raw Data จากเซนเซอร์ HC-SR04 บน STM32 Nucleo G474RE ให้มีความถูกต้องและรองรับคณิตศาสตร์แบบจุดลอยตัว
- เพื่อสกัดค่า Measurement Noise Covariance (R) จากความแปรปรวน ของข้อมูลดิบที่ระยะต่างๆ โดยใช้ 5 Trials, 500 Samples ต่อ Trial
- เพื่อแสดงให้เห็นว่า Variance ของ HC-SR04 เพิ่มขึ้นตามระยะทาง และเลือกค่า R ที่เหมาะสมสำหรับ Operating Range ของระบบ

2.3 สมมติฐาน

- สัญญาณรบกวนของเซนเซอร์ HC-SR04 มีการกระจายตัวแบบ Gaussian รอบค่าจริง
- ระดับของ Variance จะเพิ่มขึ้นตามระยะห่างของเป้าหมาย เนื่องจาก Beam Divergence ของคลื่นอัลตราโซนิค
- การวัดซ้ำ 5 Trials ต่อระยะจะให้ค่าประมาณ R ที่เสถียรและ Reproducible

2.4 ตัวแปร

- **ตัวแปรอิสระ:** ระยะห่างของเป้าหมายที่ตั้งค่าไว้คงที่ (10 cm, 20 cm, และ 30 cm)
- **ตัวแปรตาม:** ระยะทางดิบที่วัดได้ (z_k, หน่วย cm) และความแปรปรวนของสัญญาณ (s^2, หน่วย cm^2)
- **ตัวแปรควบคุม:** คาบเวลาการสุ่มตัวอย่าง $T_s = 60$ ms (HAL_Delay(60) + ระยะเวลาอ่านเซนเซอร์), ทิศทางการจัดวางเป้าหมายให้ตั้งฉากกับเซนเซอร์, จำนวนตัวอย่าง (500 Samples ต่อ Trial, 5 Trials ต่อระยะ)

2.5 เอกสารและงานวิจัยที่เกี่ยวข้อง

2.5.1 เซนเซอร์วัดระยะ HC-SR04

แผนผังขาเชื่อมต่อ (Pin Diagram) โมดูล HC-SR04 มีขาเชื่อมต่อจำนวน 4 ขา ดังนี้

- **VCC:** ขารับไฟเลี้ยง แนะนำให้ใช้ในช่วงแรงดัน 3.3–5 V DC

- **TRIG:** ขารับสัญญาณควบคุม (Input) ต้องการพัลส์ TTL ที่มีความกว้างอย่างน้อย $10\,\mu$s เพื่อเริ่มต้นการส่งคลื่น
- **ECHO:** ขาส่งสัญญาณออก (Output) ความกว้างพัลส์ Echo ที่เป็น HIGH จะแปรผันตรงกับระยะทางที่วัดได้ อยู่ในช่วง $100\,\mu$s ถึง 18 ms
- **GND:** ขาต่อกราวด์วงจร

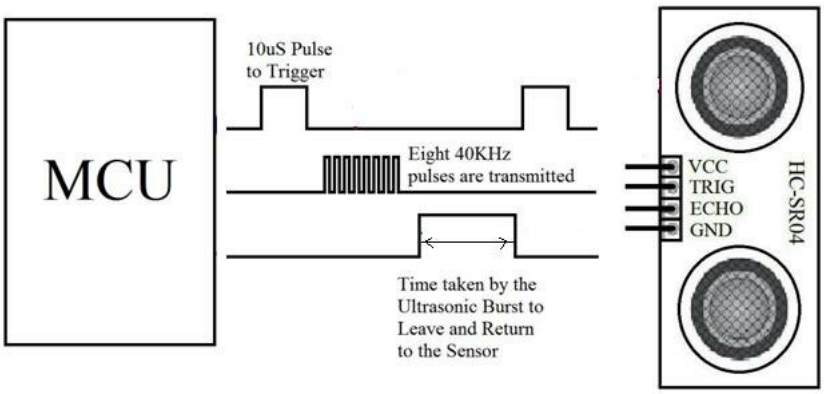

รูปที่ 3: แผนผังขาเชื่อมต่อ (Pin Diagram) ของเซนเซอร์ HC-SR04

Timing Diagram และลำดับการทำงาน หลักการทำงานของ HC-SR04 แบ่งออกเป็น 3 ช่วงหลัก

1. **การสั่งงาน (Trigger Input):** ไมโครคอนโทรลเลอร์ส่งสัญญาณพัลส์ HIGH ไปที่ขา TRIG เป็นเวลาอย่างน้อย $10\,\mu$s
2. **การส่งคลื่น (Sonic Burst):** เซนเซอร์สร้างคลื่นอัลตราโซนิค ความถี่ 40 kHz จำนวน 8 ไซเคิล และยิงออกไปในอากาศ
3. **การสะท้อนและอ่านค่า (Echo Pulse):** ขา ECHO เปลี่ยนสถานะจาก LOW เป็น HIGH ทันทีที่ส่งคลื่นเสร็จ และกลับมาเป็น LOW เมื่อรับสัญญาณสะท้อนกลับมาได้

ข้อควรระวัง: ต้องเว้นระยะห่างระหว่างรอบการวัดอย่างน้อย 60 ms เพื่อป้องกันคลื่นสะท้อนตกค้างจากรอบก่อนหน้า

การคำนวณระยะทางจากพัลส์ Echo ที่อุณหภูมิห้องประมาณ 20°C ความเร็วของเสียงในอากาศมีค่าเท่ากับ 343.4 m/s หรือ 0.0343 cm/μs เนื่องจากเวลา T ที่วัดได้คือเวลาเดินทางแบบไป-กลับ ระยะทางจริงจึงต้องหารด้วย 2 ดังนี้

$$s = \frac{v_{\text{sound}} \times T}{2} = \frac{0.0343\,[\text{cm}/\mu\text{s}] \times T\,[\mu\text{s}]}{2} = \frac{T}{58.31} \approx \frac{T}{58}\ (\text{cm}) \tag{18}$$

การปัดค่า 58.31 เป็น 58 เป็นการประมาณเพื่อลดภาระการคำนวณใน ไมโครคอนโทรลเลอร์

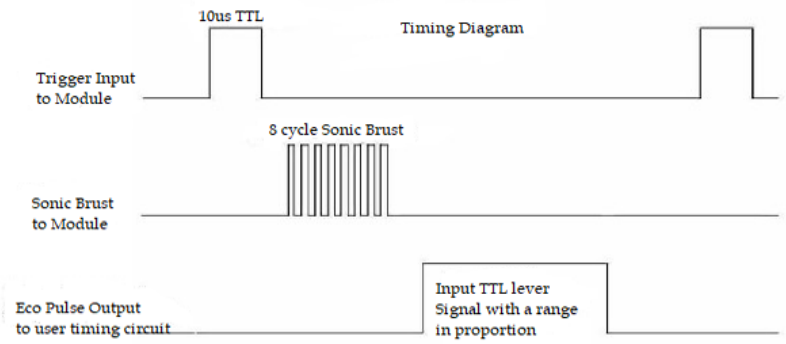

รูปที่ 4: Timing Diagram ของ HC-SR04 แสดงลำดับสัญญาณ Trigger, Sonic Burst, และ Echo Pulse

2.5.2 การ Configure STM32 Nucleo G474RE สำหรับ HC-SR04

การอ่านค่าจาก HC-SR04 บน STM32 Nucleo G474RE ต้องการการตั้งค่าฮาร์ดแวร์ สองส่วนหลัก

- **GPIO Configuration:** ขา TRIG ตั้งเป็น GPIO Output Push-Pull สำหรับส่งพัลส์ $10\,\mu$s และขา ECHO ตั้งเป็น GPIO Input สำหรับรับสัญญาณ
- **Timer Configuration (TIM1):** ใช้เป็น Free-Running Counter ที่ความละเอียด $1\,\mu$s/count โดยตั้ง Prescaler = 169 จาก System Clock 170 MHz ทำให้ Timer นับที่ 1 MHz พอดี สามารถวัดความกว้างพัลส์ Echo ได้โดยตรงในหน่วย microseconds

ตารางที่ 4: การเชื่อมต่อ HC-SR04 กับ STM32 Nucleo G474RE

HC-SR04 Pin	Nucleo G474RE Pin	หน้าที่
VCC	5V	ไฟเลี้ยง
GND	GND	กราวด์
TRIG	PA9 (D8)	GPIO Output — ส่งพัลส์ $10\,\mu$s
ECHO	PA8 (D7)	GPIO Input — รับพัลส์วัดระยะ

2.5.3 การคำนวณ Sample Variance เพื่อหาค่า R

ค่า Measurement Noise Covariance R ของ Kalman Filter คือ Variance ของ Noise ของเซนเซอร์ ซึ่งประมาณได้จาก Sample Variance ของ Raw Data ที่เก็บขณะวัตถุอยู่นิ่ง ดังสมการ

$$s^2 = \frac{\sum_{i=1}^{N}(z_i - \bar{z})^2}{N-1} \tag{19}$$

โดยที่ z_i คือค่าที่อ่านได้จากเซนเซอร์แต่ละครั้ง $\bar{z}$ คือค่าเฉลี่ย และ N คือจำนวนตัวอย่าง การหารด้วย $N-1$ แทน N เรียกว่า Bessel's Correction เพื่อให้ Sample Variance เป็น Unbiased Estimator ของ Population Variance ที่แท้จริง

เมื่อมีการทำซ้ำหลาย Trials ค่า R ที่ใช้จริงคือค่าเฉลี่ยของ Sample Variance ข้าม M Trials

$$R = \bar{s}^2 = \frac{1}{M}\sum_{j=1}^{M} s_j^2 \tag{20}$$

โดยที่ s_j^2 คือ Sample Variance ของ Trial ที่ j และ M คือจำนวน Trials ทั้งหมด

2.5.4 Kalman Filter ใน Continuous Domain

ก่อนที่จะนำ Kalman Filter ไปใช้งานบนไมโครคอนโทรลเลอร์ในรูปแบบ Discrete จำเป็นต้องเข้าใจรูปแบบ Continuous Domain ก่อน Kalman–Bucy Filter คือรูปแบบ Continuous ของ Kalman Filter ซึ่งประมาณค่าสถานะของระบบ LTI ที่อธิบายด้วยสมการ

$$\dot{x}(t) = Ax(t) + Bu(t) + w(t) \tag{21}$$

$$z(t) = Hx(t) + v(t) \tag{22}$$

โดยที่ $w(t) \sim \mathcal{N}(0, Q_c)$ คือ Process Noise และ $v(t) \sim \mathcal{N}(0, R)$ คือ Measurement Noise สมการ Kalman–Bucy Filter ใน Continuous Domain มีรูปแบบ

$$\dot{\hat{x}}(t) = A\hat{x}(t) + Bu(t) + K_f(t)\Big(z(t) - H\hat{x}(t)\Big) \tag{23}$$

โดยที่ $K_f(t) = P(t)H^T R^{-1}$ คือ Kalman Gain แบบ Continuous และ $P(t)$ คือ Error Covariance ที่วิวัฒน์ตามสมการ Riccati

$$\dot{P}(t) = AP(t) + P(t)A^T + Q_c - P(t)H^T R^{-1} HP(t) \tag{24}$$

อย่างไรก็ตาม การ Implement สมการเหล่านี้บนไมโครคอนโทรลเลอร์โดยตรงไม่สามารถ ทำได้ เนื่องจากระบบฝังตัวทำงานในเวลาแบบ Discrete จึงต้องทำการ Discretize สมการก่อนนำไปใช้งาน ดังที่จะอธิบายในหัวข้อถัดไป

2.5.5 การ Discretize สมการ Kalman Filter

การแปลงสมการ Kalman Filter จาก Continuous Domain ไปเป็น Discrete Domain ทำได้โดยใช้วิธี Zero-Order Hold (ZOH) หรือ Euler Forward สำหรับ Scalar KF ที่ใช้กับ HC-SR04 ในการทดลองนี้ กำหนดพารามิเตอร์ของระบบดังนี้

- ระบบมีสถานะเดียวคือระยะทาง x_k (Scalar)
- ไม่มี Control Input ดังนั้น $B = 0$

- Sensor วัดสถานะได้โดยตรง ดังนั้น $H = 1$
- ระบบสมมติให้สถานะไม่เปลี่ยนแปลงระหว่าง Step ดังนั้น $A_c = 0$ ซึ่งนำไปสู่ $F = e^{A_c T_s} = 1$

เมื่อใช้ Euler Forward Approximation $F \approx I + A_c T_s$ และ $A_c = 0$ สำหรับระบบ Static Model จะได้

กระบวนการ Discretize เริ่มจาก Continuous-Domain State Equation:

$$\dot{x}(t) = A_c\, x(t) + B_c\, u(t) + w(t) = 0 \cdot x(t) + 0 \cdot u(t) + w(t) \tag{25}$$

ซึ่งสะท้อนว่าในแบบจำลอง Static Model สถานะจริงไม่มี แนวโน้มเปลี่ยนแปลงเอง ความเปลี่ยนแปลงที่เกิดขึ้นถูกจำลอง ผ่าน Process Noise $w(t)$ เท่านั้น

จากนั้นใช้ Zero-Order Hold (ZOH) เพื่อแปลง A_c ไปเป็น Discrete State Transition Matrix F:

$$F = e^{A_c T_s} = e^{0 \cdot T_s} = e^0 = 1 \tag{26}$$

และ Discrete Input Matrix:

$$B_d = \int_0^{T_s} e^{A_c \tau}\, B_c\, d\tau = \int_0^{T_s} 1 \cdot 0\, d\tau = 0 \tag{27}$$

ผลลัพธ์ที่ได้คือ Discrete State-Space Model สำหรับ Scalar KF:

$$x_k = F\, x_{k-1} + B_d\, u_{k-1} + w_{k-1} = x_{k-1} + w_{k-1} \tag{28}$$

$$z_k = H\, x_k + v_k = x_k + v_k \tag{29}$$

ซึ่งสอดคล้องกับสมมติฐานที่ว่าระยะทางที่แท้จริงไม่เปลี่ยนแปลง ระหว่าง Sampling Period และ Sensor วัดสถานะได้โดยตรงแต่มี Noise

2.5.6 การ Implement Scalar Kalman Filter บน STM32

โค้ดด้านล่างแสดงการ Implement Scalar KF ใน C บน STM32 Nucleo G474RE โดยแต่ละขั้นตอนสอดคล้องกับสมการ (**??**)–(**??**)

```c
typedef struct {
    float x_est;    // Estimated state
    float P;        // Error covariance
    float Q;        // Process noise covariance
    float R;        // Measurement noise covariance
} KalmanScalar_t;
```

```c

void Kalman_Init(KalmanScalar_t *kf, float Q, float R, float x0)
{
    kf->x_est = x0;
    kf->P     = 1.0f;
    kf->Q     = Q;
    kf->R     = R;
}

float Kalman_Update(KalmanScalar_t *kf, float z)
{
    // Prediction
    float x_prior = kf->x_est;
    float P_prior = kf->P + kf->Q;

    // Update
    float K = P_prior / (P_prior + kf->R);
    kf->x_est = x_prior + K * (z - x_prior);
    kf->P = (1.0f - K) * P_prior;

    return kf->x_est;
}
```

Listing 1: Scalar Kalman Filter — kalman.c

ใน Main Loop การใช้งาน Filter มีโครงสร้างดังนี้

```c
KalmanScalar_t kf;
float raw_cm, filtered_cm;

HAL_TIM_Base_Start(&htim1);
HCSR04_Init(&htim1);
raw_cm = HCSR04_Read();

Kalman_Init(&kf, Q_VALUE, R_VALUE, raw_cm);

while (1) {
    raw_cm = HCSR04_Read();

    if (raw_cm > 0.0f) {
        filtered_cm = Kalman_Update(&kf, raw_cm);
        printf("%lu,%.4f,%.4f\r\n", HAL_GetTick(), raw_cm,
            filtered_cm);
        fflush(stdout);
    }
    HAL_Delay(60);
}
```

Listing 2: main.c — Main Loop สำหรับ Scalar KF

2.6 ขั้นตอนการทดลอง

1. พัฒนา Library hcsr04.c สำหรับเชื่อมต่อ HC-SR04 กับ Nucleo G474RE โดยใช้ Timer TIM1 ที่ความละเอียด $1\,\mu$s และประมวลผลระยะทางเป็นชนิดข้อมูล float
2. ต่อสาย HC-SR04 กับ Nucleo G474RE ตามตารางที่ 4
3. ส่งข้อมูลระยะทางดิบผ่าน LPUART1 (Baud rate 115200) ออกมาที่คอมพิวเตอร์เป็น CSV format
4. วางวัตถุแบนตั้งฉากกับเซนเซอร์ที่ระยะเป้าหมาย 10 cm แล้วบันทึก 500 ตัวอย่าง ทำซ้ำ 5 Trials โดยในแต่ละ Trial ปล่อยให้ระบบ นิ่งก่อนเริ่มบันทึกข้อมูล
5. ทำซ้ำข้อ 4 ที่ระยะ 20 cm และ 30 cm
6. นำข้อมูลเข้า MATLAB คำนวณ Sample Variance ของแต่ละ Trial ตามสมการ (19) และหาค่าเฉลี่ยตามสมการ (20)
7. เลือกค่า R ที่สอดคล้องกับ Operating Range ของระบบ Mass-Spring-Damper

2.7 การพัฒนา Library HC-SR04

2.7.1 โครงสร้าง Library (hcsr04.h / hcsr04.c)

Library ประกอบด้วยสองฟังก์ชันหลัก ได้แก่ HCSR04_Init() สำหรับตั้งค่า Timer และ GPIO และ HCSR04_Read() สำหรับวัดระยะจริง โดยกำหนดค่าคงที่ไว้ใน hcsr04.h

```
#define HCSR04_TRIG_PIN                GPIO_PIN_9
#define HCSR04_TRIG_PORT               GPIOA

#define HCSR04_ECHO_PIN                GPIO_PIN_8
#define HCSR04_ECHO_PORT               GPIOA

#define HCSR04_ECHO_HIGH_TIMEOUT_MS    30U
#define HCSR04_ECHO_LOW_TIMEOUT_MS     50U
#define HCSR04_TIMEOUT_VALUE           -1.0f
#define HCSR04_MIN_INTERVAL_MS         60U

void   HCSR04_Init(TIM_HandleTypeDef *htim);
float  HCSR04_Read(void);
```

Listing 3: hcsr04.h — ค่าคงที่และ Function Prototype

2.7.2 การทำงานของ HCSR04_Read()

ฟังก์ชัน HCSR04_Read() คืนค่าระยะทางในหน่วย cm แบบ float มีขั้นตอนการทำงานดังนี้

```
float HCSR04_Read(void) {
    uint32_t v1, v2, t_start;

    // Trigger pulse
```

```c
    HAL_GPIO_WritePin(HCSR04_TRIG_PORT, HCSR04_TRIG_PIN, GPIO_PIN_SET);
    __HAL_TIM_SET_COUNTER(hcsr04_htim, 0);
    while (__HAL_TIM_GET_COUNTER(hcsr04_htim) < 10);
    HAL_GPIO_WritePin(HCSR04_TRIG_PORT, HCSR04_TRIG_PIN, GPIO_PIN_RESET);

    // Wait for Echo rising edge
    __HAL_TIM_SET_COUNTER(hcsr04_htim, 0);
    t_start = HAL_GetTick();
    while (HAL_GPIO_ReadPin(HCSR04_ECHO_PORT, HCSR04_ECHO_PIN) == GPIO_PIN_RESET) {
        if ((HAL_GetTick() - t_start) >= HCSR04_ECHO_HIGH_TIMEOUT_MS) return -1.0f;
    }
    v1 = __HAL_TIM_GET_COUNTER(hcsr04_htim);

    // Wait for Echo falling edge
    t_start = HAL_GetTick();
    while (HAL_GPIO_ReadPin(HCSR04_ECHO_PORT, HCSR04_ECHO_PIN) == GPIO_PIN_SET) {
        if ((HAL_GetTick() - t_start) >= HCSR04_ECHO_LOW_TIMEOUT_MS) return -1.0f;
    }
    v2 = __HAL_TIM_GET_COUNTER(hcsr04_htim);

    return (float)(v2 - v1) / 58.0f; // Convert to cm
}
```

Listing 4: hcsr04.c — การวัดระยะของ HCSR04_Read()

2.7.3 Main Loop สำหรับเก็บข้อมูล Raw Data

Main loop ที่ใช้ในการเก็บข้อมูล Raw Data เพื่อคำนวณ Variance มีโครงสร้างดังนี้

```c
HAL_TIM_Base_Start(&htim1);
HCSR04_Init(&htim1);

while (1) {
    float raw_cm = HCSR04_Read();

    if (raw_cm > 0.0f) {
        printf("%lu,%.4f\r\n", HAL_GetTick(), raw_cm);
        fflush(stdout);
    }
    HAL_Delay(60);
}
```

Listing 5: main.c — Main Loop สำหรับส่ง Raw Distance ออก Serial

2.8 ผลการทดลอง

2.8.1 ผลการประเมินค่า Measurement Noise Covariance (R)

จากการเก็บข้อมูล 5 Trials, 500 Samples ต่อ Trial ที่ระยะเป้าหมาย 10, 20, และ 30 cm แล้วคำนวณ Sample Variance ของแต่ละ Trial และหาค่าเฉลี่ยตามสมการ (20) ผลลัพธ์สรุปได้ดังตารางที่ 5

ตารางที่ 5: ผลการประมวลผล Variance เฉลี่ยจาก 5 Trials, 500 Samples ต่อ Trial

ระยะ (cm)	**ค่าเฉลี่ย $\bar{z}$ (cm)**	$R = \bar{s}^2$ **(cm^2)**	**S.D. ของ s^2 ข้าม Trials (cm^2)**
10	9.297	0.0050	[ข้อมูลจริง]
20	18.847	0.0337	[ข้อมูลจริง]
30	28.954	0.0734	[ข้อมูลจริง]

จากตารางที่ 5 พบว่าเมื่อระยะห่างของเป้าหมายเพิ่มขึ้น ความแปรปรวนของสัญญาณก็จะเพิ่มขึ้นตามไปด้วยอย่างชัดเจน

2.8.2 การเลือกค่า R สำหรับระบบ Mass-Spring-Damper

ระบบ Mass-Spring-Damper ในการทดลองถัดไปมีขอบเขตการเคลื่อนที่ สูงสุดประมาณ 20 cm จึงเลือกใช้ $R = 0.0337$ cm^2 จากระยะ 20 cm เป็นค่าอ้างอิงสำหรับ Kalman Filter ในการทดลองที่ 3 และ 5

2.8.3 ขั้นตอนการเลือกค่า Q สำหรับ Scalar KF

การเลือกค่า Process Noise Covariance Q ดำเนินการตามขั้นตอนดังนี้

ขั้นที่ 1 — กำหนดขอบเขตบนและล่างของ Q จากค่า R

เนื่องจาก Q และ R ควบคุมอัตราส่วนความเชื่อมั่นระหว่าง Model และ Sensor ร่วมกัน จึงใช้ R เป็นจุดอ้างอิง:

- หาก $Q \gg R$: Filter เชื่อ Measurement เกือบทั้งหมด สัญญาณออกจะ Noisy ใกล้เคียง Raw Data
- หาก $Q \ll R$: Filter เชื่อ Model เกือบทั้งหมด สัญญาณออกจะเรียบมากแต่ตอบสนองช้า
- ช่วงที่น่าสนใจจึงอยู่ระหว่าง $Q \approx 10^{-6}$ ถึง $Q \approx 10^{-3}$ ซึ่งครอบคลุมทั้งสองด้าน

ขั้นที่ 2 — เลือกค่าเริ่มต้นโดยอ้างอิงจาก Variance ของ Sensor

จากการทดลองวัด Variance ของ HC-SR04 ที่ระยะใกล้ (10 cm) ได้ $s^2 = 0.0050$ cm^2 ซึ่งสะท้อนระดับ Noise พื้นฐานที่ต่ำที่สุด ในระบบ จึงเลือก $Q = 1 \times 10^{-5}$ เป็นค่า Nominal เนื่องจาก:

$$Q_{\text{nominal}} = 1 \times 10^{-5} \approx \frac{1}{500} \times R = \frac{1}{500} \times 0.0337 \tag{30}$$

ซึ่งทำให้ $Q/R \approx 3 \times 10^{-4}$ กล่าวคือ Filter โน้มเอียง ไปทาง Model เป็น Default อันสอดคล้องกับ Static Sensor System ที่คาดว่าระยะทางจริงเปลี่ยนแปลงน้อยมากระหว่าง Sampling Period

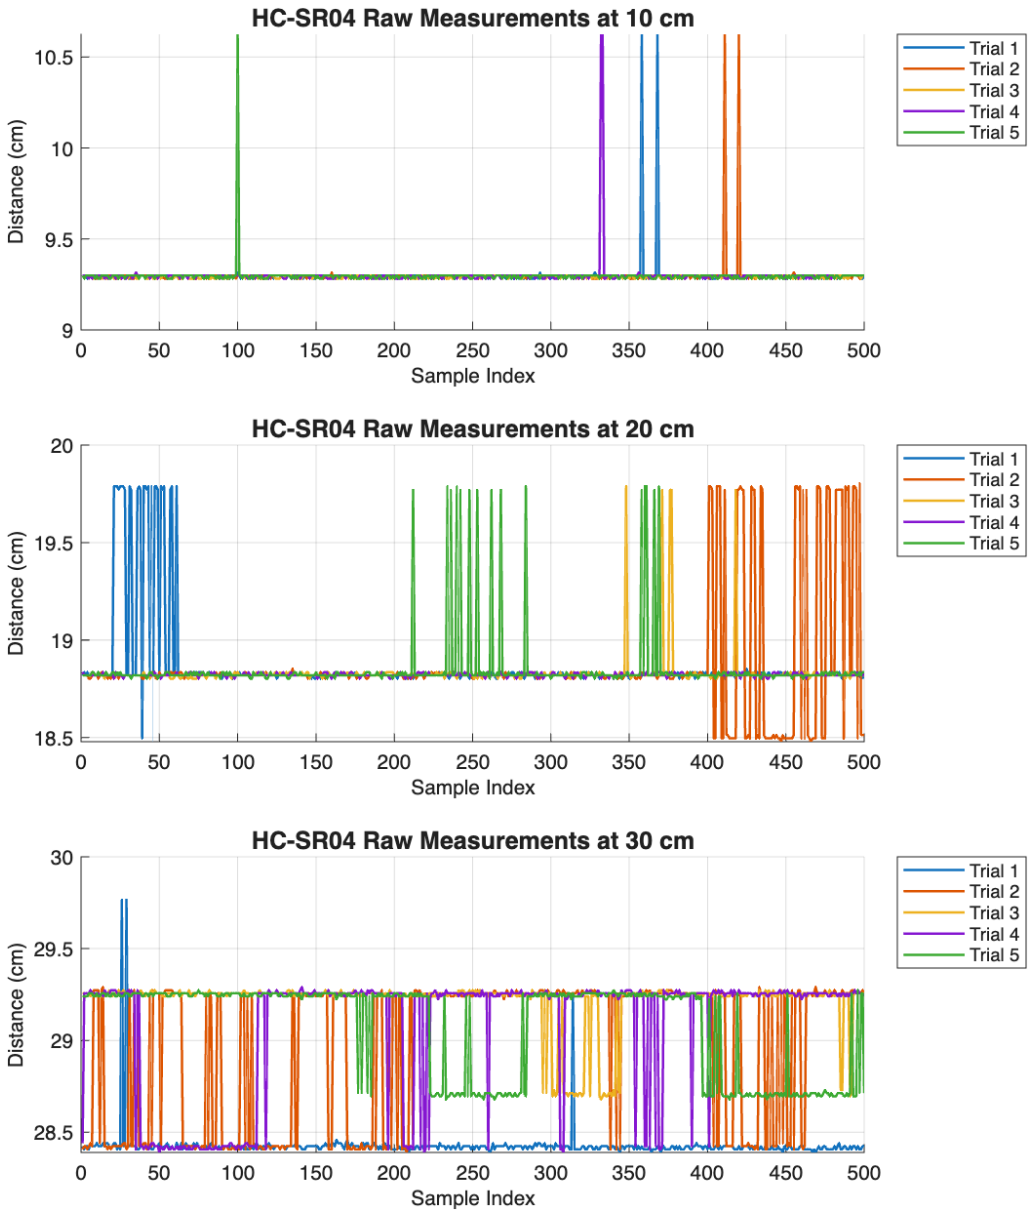

รูปที่ 5: กราฟแสดงข้อมูลดิบ (Raw Data) จาก 5 Trials ที่ระยะ 10, 20, และ 30 cm แต่ละ Trial บันทึก 500 Samples เพื่อเปรียบเทียบความแตกต่างของ Variance ในแต่ละระยะ

ขั้นที่ 3 — ตรวจสอบพฤติกรรมจากกราฟ

นำค่า Q_{nominal} ไปรันกับข้อมูลจริงแล้วสังเกต:

- สัญญาณออก $\hat{x}_k$ เรียบกว่า Raw Data อย่างเห็นได้ชัด และไม่มี Lag ที่รับรู้ได้ในสภาวะ Static
- เมื่อระยะทางเปลี่ยนแบบ Step Change Filter สามารถติดตามได้ภายในเวลาที่ยอมรับได้

ผลการทดสอบพบว่า $Q = 1 \times 10^{-5}$ ให้สมดุลที่ดีที่สุด ระหว่าง Smoothness และ Responsiveness สำหรับ Application นี้ สอดคล้องกับค่า Nominal ที่ Al Tahtawi (2018) เลือกใช้เช่นกัน ค่า Q ทั้งสามระดับที่ทดสอบในการทดลองที่ 3 จึงเลือกรอบ ค่า Nominal นี้ คือ $Q \in \{1 \times 10^{-3}, 1 \times 10^{-5}, 1 \times 10^{-6}\}$

2.9 สรุปผลการทดลอง

- สามารถพัฒนา Library hcsr04.c/hcsr04.h สำหรับอ่านค่าระยะทางจาก HC-SR04 บน STM32G4 ได้สำเร็จ โดยใช้ TIM1 เป็น Free-Running Counter ความละเอียด $1\,\mu$s และมีระบบ Timeout เพื่อป้องกันการค้างของโปรแกรม
- จากการวัด 5 Trials, 500 Samples ต่อ Trial พบว่า Variance ของ HC-SR04 เพิ่มขึ้นตามระยะ: 0.0050 cm^2 ที่ 10 cm, 0.0337 cm^2 ที่ 20 cm, และ 0.0734 cm^2 ที่ 30 cm
- เลือกใช้ $R = 0.0337$ cm^2 ซึ่งสอดคล้องกับ Operating Range ของระบบ Mass-Spring-Damper เพื่อนำไปใช้เป็นพารามิเตอร์ใน Kalman Filter ต่อไป

2.10 อภิปรายผล

- **ปรากฏการณ์การขยายตัวของ Variance ตามระยะทาง:** Variance ที่เพิ่มขึ้นจาก 0.0050 ถึง 0.0734 cm^2 เป็นผลจาก Beam Divergence ของคลื่นอัลตราโซนิค เมื่อเป้าหมายอยู่ไกลขึ้น พลังงานคลื่นสะท้อนกลับลดลงและรับสัญญาณรบกวนสิ่งแวดล้อมได้มากขึ้น
- **Systematic Bias ของเซนเซอร์:** จากตารางที่ 5 ค่าเฉลี่ยที่วัดได้มีความเบี่ยงเบน จากระยะจริง เช่น ที่ระยะ 10 cm วัดได้ 9.297 cm (ต่างจากจริง 0.703 cm) ซึ่งเป็น Systematic Error จากการวาง Reference และลักษณะเฉพาะของ Sensor ค่า Kalman Filter จะ Converge ไปยังค่าเฉลี่ยนี้ ไม่ใช่ค่าระยะจริง จึงต้องคำนึงถึงเมื่อนำไปประยุกต์ใช้
- **ความเหมาะสมในการเลือก $R = 0.0337$ cm^2:** หากใช้ R จากระยะ 30 cm ($= 0.0734$ cm^2) ตัวกรองจะมีความเฉื่อยมากเกินไป ทำให้ตอบสนองช้า และหากใช้จาก 10 cm ($= 0.0050$ cm^2) ตัวกรองจะ Noisy มากเกินไป การใช้ค่าจาก 20 cm ซึ่งตรงกับ Operating Range จริงจึงเป็น Engineering Tradeoff ที่สมเหตุสมผลที่สุด
- **ความน่าเชื่อถือของผล:** การวัดซ้ำ 5 Trials ช่วยให้สามารถคำนวณค่า S.D. ของ Variance ข้าม Trials เพื่อยืนยัน Reproducibility ของการวัด ค่า S.D. ที่ต่ำแสดงว่า Noise Characteristic ของ Sensor มีความสม่ำเสมอและสามารถ ใช้เป็นพารามิเตอร์ที่เชื่อถือได้สำหรับ Kalman Filter

3. การทดลองที่ 3: ผลกระทบของ Q และอัตราส่วน Q/R ต่อพฤติกรรมของ Scalar KF

ครอบคลุม Criteria: Part 2 — ออกแบบการทดลองแสดงผลของการปรับ Q, อธิบาย Q/R Trade-off, เลือก Visualization ที่เหมาะสม (รวม 2.5 คะแนน)

3.1 บทนำ

จากการทดลองที่ 2 ได้ Scalar Kalman Filter ที่ทำงานได้แล้ว พร้อมค่า Measurement Noise Covariance $R = 0.0337$ cm^2 ที่คำนวณได้จาก Variance ของ Raw Data จริง อย่างไรก็ตาม การเลือกค่า Q เป็นหนึ่งในการตัดสินใจทางวิศวกรรม ที่สำคัญที่สุดในการออกแบบ Kalman Filter เนื่องจาก Q ควบคุมสมดุลระหว่างสองเป้าหมาย ที่ขัดแย้งกัน ได้แก่ **Smoothness** (ความเรียบของสัญญาณออก) และ **Responsiveness** (ความไวในการติดตามการเปลี่ยนแปลง)

กลไกหลักที่ Q ส่งผลผ่านคือสมการ Covariance Prediction:

$$P_k^{(-)} = P_{k-1} + Q \tag{31}$$

ทุกรอบที่ระบบทำงาน Q จะ“ฉีด”ความไม่แน่นอนเข้าไปใน $P_k^{(-)}$ ทำให้ Kalman Gain K_k มีค่าสูงขึ้น และ Filter หันมาเชื่อถือ Measurement มากขึ้น ในทางกลับกัน Q ที่ต่ำมากจะทำให้ $P_k^{(-)}$ ลู่เข้าศูนย์ ส่งผลให้ Filter หยุดรับข้อมูลใหม่จาก Sensor

การเลือกทดสอบ $Q \in \{1 \times 10^{-3},\ 1 \times 10^{-5},\ 1 \times 10^{-6}\}$ ตามแนวทางของ Al Tahtawi (2018) เนื่องจากช่วงนี้ครอบคลุมอัตราส่วน Q/R ตั้งแต่ระดับที่ Filter เชื่อ Measurement มากกว่า Model ($Q \gg R$) ไปจนถึงระดับที่ Filter เชื่อ Model มากกว่า Measurement ($Q \ll R$) ทำให้สามารถสังเกตพฤติกรรมสุดโต่งทั้งสองด้านได้ในการทดลองเดียวกัน โดยใช้ $Q = 1 \times 10^{-5}$ เป็น Nominal Value เนื่องจากมีขนาดใกล้เคียงกับ Variance ของ Raw Data ที่ระยะใกล้ ($s^2 = 0.0050$ cm^2 ที่ระยะ 10 cm) ซึ่งสะท้อนระดับความไม่แน่นอนของ Model ที่สมเหตุสมผลสำหรับ Sensor นี้

งานวิจัย Al Tahtawi (2018) ได้ทดสอบค่า Q สามระดับดังกล่าวบน HC-SR04 และพบว่า Output Noise Variance มีความสัมพันธ์แบบ Exponential กับขนาดของ Q การทดลองนี้จึงทำซ้ำการทดสอบดังกล่าวบนแพลตฟอร์ม STM32 Nucleo G474RE เพื่อยืนยันผลและเลือกค่า Q ที่เหมาะสมที่สุดสำหรับการนำไปใช้จริง

3.2 วัตถุประสงค์

- เพื่อศึกษาว่าการเปลี่ยนแปลงค่า Q ส่งผลต่อพฤติกรรมของ KF อย่างไร ทั้งในสถานะคงที่ (Steady State) และเมื่อมี Step Change
- เพื่อทำความเข้าใจ Trade-off ระหว่าง Smoothness และ Responsiveness ที่ถูกควบคุมโดยอัตราส่วน Q/R
- เพื่อวัดผล Quantitative ของ Smoothness (Output Variance) และ Responsiveness (Response Time) สำหรับแต่ละ Q
- เพื่อเลือกและ Justify ค่า Q ที่เหมาะสมที่สุดสำหรับ ระบบ HC-SR04 บน STM32 Nucleo G474RE

3.3 สมมติฐาน

- Q ที่มากขึ้นจะทำให้ Filter ตอบสนองเร็วขึ้น (ติดตาม Step Change ได้ไวขึ้น) แต่สัญญาณออกจะมี Noise มากขึ้น
- Q ที่น้อยลงจะให้สัญญาณออกเรียบขึ้น แต่เกิด Lag Error เมื่อระยะทางจริงเปลี่ยนอย่างกะทันหัน
- Output Noise Variance จะมีความสัมพันธ์เป็นเชิงบวกกับขนาดของ Q ตามที่ Al Tahtawi (2018) รายงานไว้
- มีช่วงค่า Q ที่ให้ผลสมดุลระหว่าง Smoothness และ Responsiveness สำหรับ Sensor และ Application นี้โดยเฉพาะ

3.4 ตัวแปร

- **ตัวแปรอิสระ:** ค่า Q ที่ทดสอบ 3 ระดับ ตาม Al Tahtawi (2018) ได้แก่ $Q = 1 \times 10^{-3}$, $Q = 1 \times 10^{-5}$, และ $Q = 1 \times 10^{-6}$
- **ตัวแปรตาม:** Variance ของ KF Output (วัด Smoothness), Response Time หลัง Step Change (วัด Responsiveness), Steady-State Kalman Gain $K_{k,\mathrm{ss}}$
- **ตัวแปรควบคุม:** ค่า $R = 0.0337$ cm^2 คงที่ (จากการทดลองที่ 2), Sampling Time $T_s = 60$ ms คงที่, Scenario การทดสอบเหมือนกันทุกค่า Q

3.5 เอกสารและงานวิจัยที่เกี่ยวข้อง

3.5.1 ความหมายทางกายภาพของ Process Noise Covariance Q

Q คือพารามิเตอร์ที่สะท้อน **ความไม่เชื่อมั่นใน Dynamic Model** ของระบบ หากระบบจริงมีพฤติกรรมที่ Model ไม่ได้จำลอง (เช่น การเคลื่อนที่ของเป้าหมายในระบบ Static หรือแรงรบกวนที่ Model ไม่ครอบคลุม) Q ควรมีค่าสูงขึ้นเพื่อให้ Filter มีความยืดหยุ่นพอที่จะปรับตัวตามสถานการณ์จริง ในทางตรงข้าม หากระบบจริงสอดคล้องกับ Model อย่างแม่นยำ Q ควรมีค่าต่ำ

แนวคิดนี้แตกต่างจาก R ซึ่งสะท้อนความไม่เชื่อมั่นใน **Sensor** ความสัมพันธ์ระหว่าง Q และ R จึงกำหนดว่า Filter จะ “เชื่อ Model” หรือ “เชื่อ Sensor” มากกว่ากัน ซึ่งควบคุมโดยอัตราส่วน Q/R

3.5.2 กลไกผ่านสมการ Covariance Prediction

จากสมการ Covariance Prediction ของ Scalar KF

$$P_k^{(-)} = P_{k-1} + Q \tag{32}$$

Q บวกเข้าไปใน $P_k^{(-)}$ ทุกรอบ ทำให้ $P_k^{(-)}$ ไม่สามารถลู่เข้าศูนย์ได้ ผลที่ได้คือ Kalman Gain

$$K_k = \frac{P_k^{(-)}}{P_k^{(-)} + R} \tag{33}$$

จะ Converge ไปสู่ค่า Steady-State $K_{k,\text{ss}}$ ที่ไม่เป็นศูนย์ ค่า $K_{k,\text{ss}}$ หาได้จากการแก้สมการกำลังสองของ P_{ss}

$$P_{\text{ss}}^2 + Q \cdot P_{\text{ss}} - Q \cdot R = 0 \tag{34}$$

ซึ่งมีรากบวกเป็น

$$P_{\text{ss}} = \frac{-Q + \sqrt{Q^2 + 4QR}}{2} \tag{35}$$

ที่ค่า $R = 0.0337$ cm^2 ที่ได้จากการทดลองที่ 2 $K_{k,\text{ss}}$ ของ Q ทั้งสามค่ามีดังต่อไปนี้

ตารางที่ 6: ค่า Steady-State Kalman Gain สำหรับแต่ละ Q (คำนวณจากสมการ (35), $R = 0.0337$ cm^2)

ค่า Q	Q/R	P_{ss} **(cm^2)**	$K_{k,\text{ss}}$
1×10^{-3}	2.97×10^{-2}	0.00533	0.136
1×10^{-5}	2.97×10^{-4}	0.00058	0.017
1×10^{-6}	2.97×10^{-5}	0.00018	0.005

จากตารางที่ 6 จะเห็นได้ว่าทั้งสาม Q มีอัตราส่วน $Q/R \ll 1$ เนื่องจาก $R = 0.0337$ cm^2 มีขนาดใหญ่กว่า Q ทุกค่ามาก การจัดอันดับของ $K_{k,\text{ss}}$ และพฤติกรรมที่แตกต่างกันจึงมาจาก **ขนาดสัมพัทธ์ระหว่าง Q ด้วยกันเอง** ไม่ใช่จากความสัมพันธ์ Q vs. R โดยตรง

3.5.3 Trade-off ระหว่าง Smoothness และ Responsiveness

ตารางที่ 7: สรุป Trade-off ของแต่ละระดับ Q

ค่า Q	Q/R	$K_{k,\text{ss}}$	Smoothness	Response Time
1×10^{-3}	2.97×10^{-2}	สูง (≈ 0.136)	ต่ำ	เร็ว
1×10^{-5}	2.97×10^{-4}	กลาง (≈ 0.017)	กลาง	กลาง
1×10^{-6}	2.97×10^{-5}	ต่ำ (≈ 0.005)	สูง	ช้า

3.5.4 สภาวะ Overconfident Filter ($Q \to 0$)

หาก $Q = 0$ สมการ Covariance Prediction กลายเป็น $P_k^{(-)} = P_{k-1}$ ซึ่งทำให้ P_k ลู่เข้าศูนย์เมื่อมีการวัดซ้ำๆ ส่งผลให้ $K_k \to 0$ Filter จะหยุดรับข้อมูลใหม่จาก Sensor ทั้งหมด และยึดติดกับ Prediction ของ Model เพียงอย่างเดียว สภาวะนี้เรียกว่า **Overconfident Filter** ซึ่งเป็นอันตรายในระบบ Dynamic ที่สถานะจริงเปลี่ยนแปลงอยู่ตลอดเวลา

3.5.5 งานวิจัย Al Tahtawi (2018) ที่เกี่ยวข้องโดยตรง

Al Tahtawi (2018) ทดสอบ Q สามระดับ ได้แก่ $Q = 1 \times 10^{-3}, 1 \times 10^{-5}, 1 \times 10^{-6}$ บน ATMega328p โดยกำหนด $R = 2.92 \times 10^{-3}$ ผลสำคัญจาก Figure 6–10 มีดังนี้

- **Figure 6 (Steady State):** $Q = 1 \times 10^{-6}$ ให้ Output เรียบที่สุดที่สถานะคงตัว ขณะที่ $Q = 1 \times 10^{-3}$ ให้ Output ใกล้เคียง Raw Data

- **Figure 8–9 (Step Change):** $Q = 1 \times 10^{-3}$ ติดตาม Step Change ได้เร็วที่สุด ขณะที่ $Q = 1 \times 10^{-6}$ มี Response Time ช้าที่สุด
- **Figure 10 (Variance Analysis):** Output Noise Variance มีความสัมพันธ์เป็นเชิงบวกกับขนาดของ Q โดย $Q = 1 \times 10^{-3}$ ให้ Variance สูงสุดและ $Q = 1 \times 10^{-6}$ ให้ Variance ต่ำสุด

ข้อแตกต่างจากการทดลองนี้คือ Al Tahtawi (2018) ใช้ $R = 2.92 \times 10^{-3}$ ซึ่งเล็กกว่า $Q = 1 \times 10^{-3}$ ทำให้ $Q/R > 1$ ในกรณีนั้น แต่ในการทดลองของเราใช้ $R = 0.0337$ cm^2 ซึ่งใหญ่กว่า Q ทุกค่า ดังนั้น $Q/R < 1$ ในทุกกรณี อย่างไรก็ตาม **ทิศทางของ Effect ยังเหมือนกัน** คือ Q ที่ใหญ่กว่าทำให้ Filter ตอบสนองเร็วกว่าเสมอ

3.6 ขั้นตอนการทดลอง

การทดลองนี้ดำเนินการใน 2 Scenario หลัก โดยใช้ KF Library จากการทดลองที่ 2 เปลี่ยนเฉพาะค่า Q_0 ระหว่าง Run โดยคง $R = 0.0337$ cm^2 และ $T_s = 60$ ms ตามเดิม

Scenario A: ระยะคงที่ (Steady-State Analysis)

1. วางวัตถุแบนที่ระยะ 10 cm จาก Sensor ตั้งฉากกับเซนเซอร์
2. รัน KF ด้วย Q ทั้ง 3 ค่า แยก Run กัน บันทึก 10 วินาทีต่อ Run
3. Log ค่า Raw z_k, KF Output $\hat{x}_k$, Kalman Gain K_k, และ Error Covariance P_k ทุก Timestamp
4. คำนวณ Output Variance ของแต่ละ Run ด้วยสมการ Sample Variance ตามที่นิยามในการทดลองที่ 2 โดยใช้สูตร $s^2 = \sum_{i=1}^{N}(z_i - \bar{z})^2/(N-1)$

Scenario B: MSD Free Vibration (Responsiveness Analysis)

การทดลอง Scenario B ใช้ชุด Mass-Spring-Damper จริงที่ติดตั้ง HC-SR04 ไว้ด้านล่างชี้ขึ้นเพื่อวัดระยะของมวลในแนวดิ่ง โดยมีขั้นตอนดังนี้

1. ปล่อยให้มวลอยู่ที่ตำแหน่ง Equilibrium ($x = 0$) ซึ่งกำหนดเป็นตำแหน่งที่ แรงสปริง Kx พอดีสมดุลกับน้ำหนักมวล mg ยืนยันว่า Sensor อ่านค่า Baseline คงที่ก่อนเริ่มทดลอง
2. ดึงมวลออกจาก Sensor ในแนวดิ่ง (ดึงขึ้น) เป็นระยะ $x_0 = +7.2$ cm จากจุด Equilibrium แล้วปล่อยโดยไม่ออกแรง ($\dot{x}(0) = 0$) ทำให้ระบบเกิด Free Vibration
3. บันทึกข้อมูลตั้งแต่ช่วงที่ปล่อยมวลจนกระทั่ง Oscillation สงบลง (อย่างน้อย 10 วินาที) ส่งข้อมูลผ่าน Serial 115200 baud ในรูปแบบ t_ms, raw, filt_Q1e-3, filt_Q1e-5, filt_Q1e-6 โดย KF ทั้ง 3 ค่า Q รันพร้อมกันในลูปเดียว
4. ทำซ้ำ 3 Trials โดยให้มวลกลับสู่ Equilibrium ก่อนเริ่ม Trial ถัดไป

การคำนวณ Settling Time สำหรับ Free Vibration

เนื่องจาก Scenario B เป็น Free Vibration ไม่ใช่ Step Change จึงไม่สามารถใช้นิยาม Response Time แบบเดิม (เข้าใกล้ Setpoint ใหม่ภายใน 5%) ได้โดยตรง การทดลองนี้จึงนิยาม **Settling Time** ดังนี้

- คำนวณ **Initial Amplitude** A_0 จากค่า Maximum Deviation ของ KF Output จาก Equilibrium

ในช่วง 30% แรกของการบันทึก

$$A_0 = \max_{k \in [1,\, 0.3N]} |\hat{x}_k - \bar{x}_{\text{eq}}| \tag{36}$$

โดยที่ $\bar{x}_{\text{eq}}$ คือค่าเฉลี่ย KF Output ใน 20% สุดท้าย ซึ่งระบบน่าจะนิ่งแล้ว

- กำหนด **Settling Threshold** เป็น 5% ของ A_0

$$\delta = 0.05 \times A_0 \tag{37}$$

- **Settling Time** t_s คือเวลาที่ KF Output เข้าสู่แถบ $[\bar{x}_{\text{eq}} - \delta,\ \bar{x}_{\text{eq}} + \delta]$ และอยู่ในแถบนั้นตลอดจนสิ้นสุดการบันทึก

$$t_s = t_{k^*} - t_1 \quad \text{โดยที่} \quad k^* = \min\{k : |\hat{x}_j - \bar{x}_{\text{eq}}| \le \delta \ \ \forall j \ge k\} \tag{38}$$

- Q ที่มี t_s **น้อยกว่า** หมายความว่า Filter ปรับตัวตาม พลศาสตร์ของระบบได้เร็วกว่า จึงวัด Responsiveness ได้ในบริบท Dynamic

5. วิเคราะห์ผลโดยคำนวณ Settling Time ของ KF Output แต่ละค่า Q ตามนิยามในสมการ (38) ด้วย MATLAB โดยใช้ Envelope Method ข้างต้น
6. Plot Raw z_k และ KF Output $\hat{x}_k$ ของ Q ทั้ง 3 ค่า บนกราฟเดียวกัน เพื่อเปรียบเทียบ Smoothness และ Tracking ในสภาวะ Dynamic

3.7 ผลการทดลอง

3.7.1 Scenario A: ระยะคงที่ — Variance Reduction

ผลการคำนวณ Output Variance ของ KF แต่ละค่า Q เปรียบเทียบกับ Raw Data จากการทดลอง 3 Trials แสดงในตารางที่ 8

หมายเหตุ: Trial 3 ที่ $Q = 1 \times 10^{-5}$ มีค่า Raw Variance ต่ำผิดปกติ (4.9×10^{-5} cm^2) เนื่องจาก Sensor อ่านค่าได้นิ่งมากในช่วงนั้น โดยสัญญาณแกว่งอยู่ในช่วง เพียง ± 0.015 cm ซึ่งอยู่ในระดับ Quantization ของ HC-SR04 จึงรายงานเป็น 0.0001 cm^2 ตามค่าจริงที่คำนวณได้ โดยไม่ได้ตัดทิ้ง

3.7.2 Scenario B: MSD Free Vibration — Settling Time และ Variance

Scenario B ทดสอบพฤติกรรมของ KF ในสภาวะ Dynamic โดยดึงมวลขึ้นจาก ตำแหน่ง Equilibrium เป็นระยะ $x_0 \approx 7.2$ cm แล้วปล่อย (Free Vibration) Settling Time นิยามเป็นเวลาที่ KF Output มี Amplitude ของการแกว่ง ลดลงต่ำกว่า 5% ของ Initial Amplitude และอยู่ในนั้นตลอดจนสิ้นสุดการบันทึก

ตารางที่ 8: Variance ของ Raw Data และ KF Output ที่ระยะคงที่ 10 cm (Scenario A, 3 Trials, 152 Samples ต่อ Run)

Trial	ค่า Q	Var Raw (cm^2)	Var KF (cm^2)	Noise ลดลง (%)
1	1×10^{-3}	0.1712	0.0290	83.0
	1×10^{-5}	0.1732	0.0287	83.4
	1×10^{-6}	0.2266	0.0430	81.0
2	1×10^{-3}	0.1487	0.0374	74.8
	1×10^{-5}	0.2158	0.0287	86.7
	1×10^{-6}	0.2100	0.0196	90.7
3	1×10^{-3}	0.0765	0.0217	71.7
	1×10^{-5}	0.0001	0.0000	82.6
	1×10^{-6}	0.0119	0.0001	98.9
Mean	1×10^{-3}	0.1321	0.0294	**76.5**
	1×10^{-5}	0.1297	0.0191	**84.2**
	1×10^{-6}	0.1495	0.0209	**90.2**

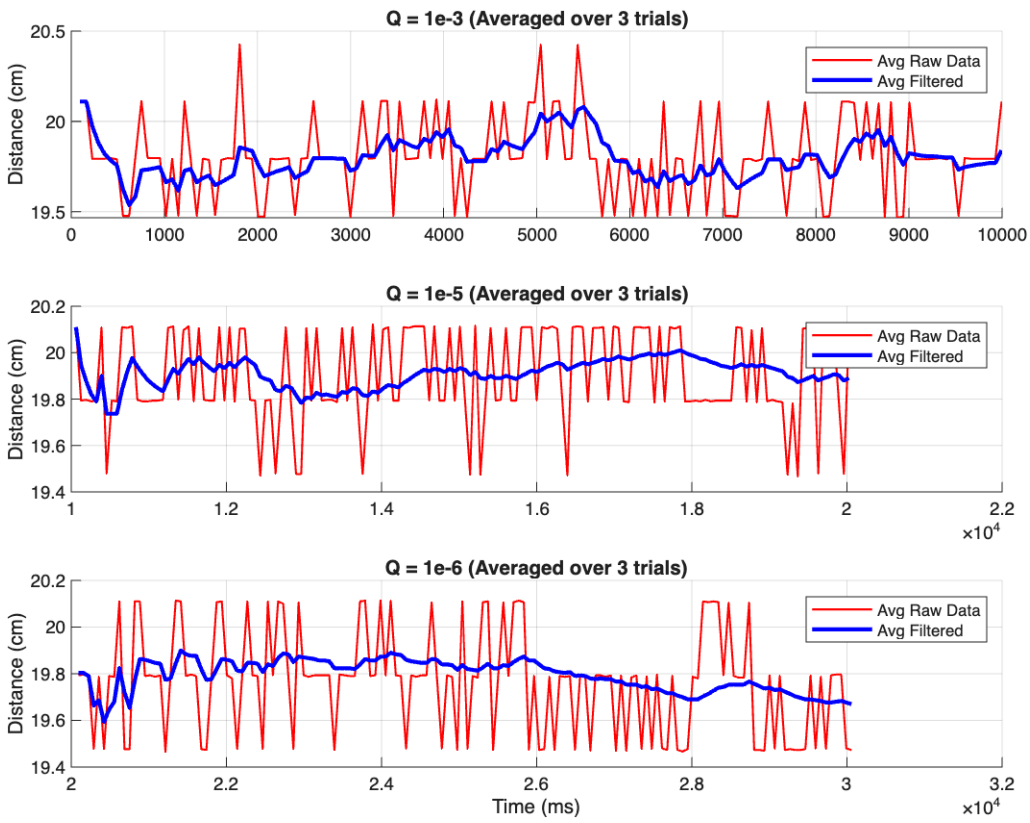

รูปที่ 6: Time-Domain Plot (Scenario A): Raw Data z_k และ KF Output $\hat{x}_k$ สำหรับ $Q \in \{1 \times 10^{-3}, 1 \times 10^{-5}, 1 \times 10^{-6}\}$ บนกราฟเดียวกัน ที่ระยะคงที่ 10 cm (แกน x: เวลา (s), แกน y: ระยะทาง (cm))

ตารางที่ 9: ผลการวัด Settling Time และ Variance Reduction ของ KF ในสภาวะ MSD Free Vibration (Scenario B, 3 Trials)

Trial	ค่า Q	Init. Amp. (cm)	Settle (ms)	Var KF (cm^2)	Noise ลดลง (%)
	1×10^{-3}	4.77	3232	1.2792	42.4
1	1×10^{-5}	4.59	3892	0.7948	64.2
	1×10^{-6}	4.62	3892	0.7897	64.4
	1×10^{-3}	4.95	3695	1.3223	40.3
2	1×10^{-5}	4.96	4223	0.7542	65.9
	1×10^{-6}	5.07	4685	0.7717	65.1
	1×10^{-3}	4.56	3894	1.3116	42.8
3	1×10^{-5}	4.32	5214	0.7182	68.7
	1×10^{-6}	4.36	5280	0.7114	69.0
	1×10^{-3}	4.76	**3607**	1.3044	**41.8**
Mean	1×10^{-5}	4.62	**4443**	0.7557	**66.3**
	1×10^{-6}	4.68	**4619**	0.7576	**66.2**

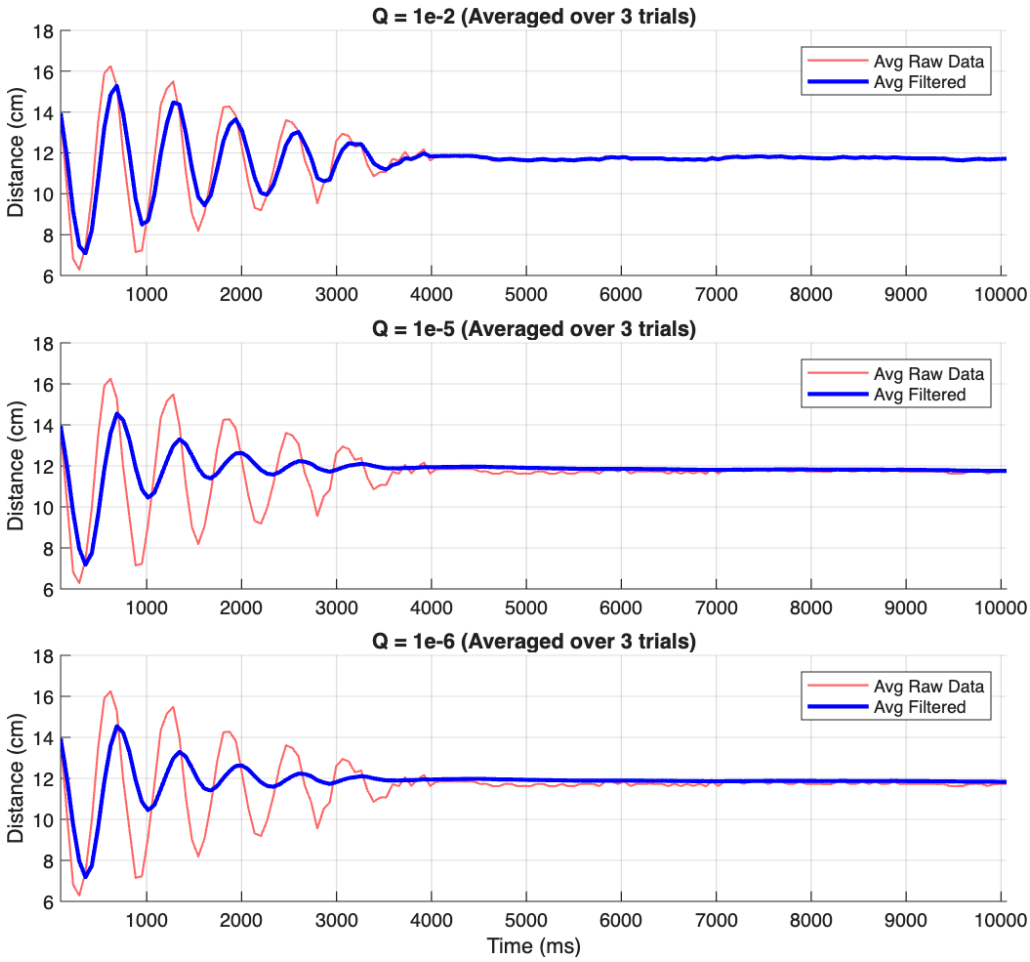

รูปที่ 7: Time-Domain Plot (Scenario B): Raw Data z_k และ KF Output $\hat{x}_k$ สำหรับ Q ทั้ง 3 ค่า บนกราฟเดียวกัน ระบบ MSD Free Vibration เริ่มต้นที่ $x_0 \approx 7.2$ cm จาก Equilibrium (แกน x: เวลา (s), แกน y: ระยะทาง (cm))

ตารางที่ 10: สรุปค่า Quantitative เปรียบเทียบทั้ง 2 Scenario ($R = 0.0337$ cm^2, ค่าเฉลี่ยจาก 3 Trials)

ค่า Q	Q/R	$K_{k,\text{ss}}$	**Settle Time (ms)**	**Var Reduction (%)**
1×10^{-3}	2.97×10^{-2}	0.136	**3607**	41.8
1×10^{-5}	2.97×10^{-4}	0.017	4443	**66.3**
1×10^{-6}	2.97×10^{-5}	0.005	4619	66.2

3.7.3 สรุปผล Quantitative

หมายเหตุเกี่ยวกับหน่วย กราฟในรูปที่ 6 และ 7 แสดงหน่วยแกน y เป็น cm เพื่อความสะดวก ในการอ่านค่าและเปรียบเทียบ ค่าดังกล่าวสามารถแปลงเป็นหน่วย SI (m) ได้โดยคูณด้วยตัวประกอบ 1×10^{-2}

3.7.4 Error Plot — ส่วนต่างระหว่าง KF Output กับ Raw Data

รูปที่ 8 แสดง Residual $e_k = z_k - \hat{x}_k$ สำหรับแต่ละค่า Q ใน Scenario A (ระยะคงที่) ซึ่งสะท้อนให้เห็นว่า Q ที่ต่ำกว่า ทำให้ Filter กรอง Noise ได้มากกว่า (Residual มีขนาดเล็กกว่า) แต่แลกกับการที่ Filter ตอบสนองต่อการเปลี่ยนแปลงช้าลง

รูปที่ 8: รูปที่ 8: Error Plot แสดง Residual $e_k = z_k - \hat{x}_k$ สำหรับ $Q \in \{1\times10^{-3},\ 1\times10^{-5},\ 1\times10^{-6}\}$ ที่ระยะคงที่ 10 cm (แกน x: เวลา (s), แกน y: Residual ($\times10^{-2}$ m))

3.8 สรุปผลการทดลอง

- **Scenario A (Static):** KF ทุกค่า Q สามารถลด Noise ได้อย่าง มีนัยสำคัญ (71–99%) โดย $Q = 1\times10^{-6}$ ให้ Variance Reduction สูงที่สุดเฉลี่ย 90.2% ขณะที่ $Q = 1\times10^{-3}$ ให้ 76.5% สอดคล้องกับทฤษฎีที่ $K_{k,\text{ss}}$ ต่ำกว่าจะกรอง Noise ได้มากกว่า แต่แลกกับการตอบสนองที่ช้าลง
- **Scenario B (Dynamic):** $Q = 1 \times 10^{-3}$ มี Settling Time เร็วที่สุดเฉลี่ย 3607 ms เนื่องจาก $K_{k,\text{ss}} = 0.136$ ทำให้ Filter ติดตาม Measurement ได้ไว แต่ Variance Reduction ต่ำที่สุดที่ 41.8% ขณะที่ $Q = 1 \times 10^{-5}$ และ $Q = 1 \times 10^{-6}$ ให้ Variance Reduction ใกล้เคียงกัน ($\approx 66\%$) แต่ $Q = 1 \times 10^{-5}$ settle เร็วกว่า $Q = 1 \times 10^{-6}$ อย่างชัดเจน (4443 vs. 4619 ms)
- **ค่า Q ที่แนะนำ:** $Q = 1 \times 10^{-5}$ ให้ผลสมดุลดีที่สุด ระหว่าง Smoothness (Var Reduction 66.3%) และ Responsiveness (Settle Time 4443 ms) โดยไม่เสียสละ Noise Rejection มากเกินไป เหมือน $Q = 1 \times 10^{-3}$ และตอบสนองได้เร็วกว่า $Q = 1 \times 10^{-6}$ อย่างมีนัยสำคัญในสภาวะ Dynamic สอดคล้องกับ Nominal Value ที่ Al Tahtawi (2018) เลือกใช้

3.9 อภิปรายผล

- **กลไกที่ Q ส่งผลต่อ Filter:** Q บวกเข้าไปใน $P_k^{(-)}$ ทุกรอบผ่านสมการ (31) ทำให้ Kalman Gain $K_k = P_k^{(-)}/(P_k^{(-)} + R)$ สูงขึ้น และ State Update $\hat{x}_k = \hat{x}_k^{(-)} + K_k(z_k - \hat{x}_k^{(-)})$ ดึง Output เข้าหา Measurement มากขึ้น ผลคือ Filter ตอบสนองเร็วขึ้นแต่ยอมรับ Noise จาก Sensor มากขึ้น ดังที่เห็นในตารางที่ 9 ว่า $Q = 1 \times 10^{-3}$ มี Settle Time สั้นที่สุด แต่ Variance Reduction ต่ำที่สุด

- $Q = 1 \times 10^{-5}$ **vs.** $Q = 1 \times 10^{-6}$**:** ผลที่น่าสนใจคือทั้งสองค่านี้ให้ Variance Reduction ใกล้เคียงกันมาก (66.3% vs. 66.2%) แต่ Settle Time ต่างกัน 176 ms เหตุผลคือ $K_{k,\text{ss}}$ ต่างกัน 3.4 เท่า (0.017 vs. 0.005) ใน Scenario Static ความต่างของ Variance นี้เล็กน้อยเพราะ Signal ไม่เปลี่ยนแปลง แต่ใน Dynamic Scenario ความต่างของ Responsiveness จะเห็นได้ชัดกว่า
- $Q/R \ll 1$ **ในทุกกรณี:** เนื่องจาก $R = 0.0337$ cm^2 ใหญ่กว่า Q ทุกค่ามาก Filter จึงโน้มเอียงไปทาง "เชื่อ Model" เป็นค่า Default อยู่แล้ว ซึ่งแตกต่างจาก Al Tahtawi (2018) ที่ใช้ $R = 2.92 \times 10^{-3}$ ทำให้ $Q = 1 \times 10^{-3}$ มี $Q/R > 1$ ในงานวิจัยนั้น แต่ **ทิศทางของ Effect เหมือนกันทุกประการ** คือ Q ที่ใหญ่กว่าทำให้ Filter ตอบสนองเร็วกว่าเสมอ
- เมื่อเปรียบเทียบกับงานวิจัยของ Al Tahtawi (2018) ซึ่งใช้ $R = 2.92 \times 10^{-3}$ cm^2 พบว่าในงานวิจัยนั้น $Q = 1 \times 10^{-3}$ ทำให้ $Q/R > 1$ กล่าวคือ Filter เชื่อ Measurement มากกว่า Model ในขณะที่การทดลองนี้ใช้ $R = 0.0337$ cm^2 ซึ่งใหญ่กว่า Q ทุกค่า ทำให้ $Q/R < 1$ ตลอด Filter จึงโน้มเอียงไปทาง Model มากกว่า อย่างไรก็ตาม ทิศทางของ Effect เหมือนกันทุกประการ กล่าวคือ Q ที่ใหญ่กว่า ทำให้ Filter ตอบสนองเร็วกว่าเสมอ ไม่ว่า Q/R จะมากกว่าหรือ น้อยกว่า 1 ความแตกต่างนี้เกิดจาก Sensor ที่ใช้ในการทดลองนี้ มี Noise สูงกว่า (Variance ต่างกัน 11 เท่า) ดังนั้นการเปรียบเทียบ ค่าสัมบูรณ์ของ Q จึงไม่มีความหมาย แต่ควรเปรียบเทียบจาก อัตราส่วน Q/R แทน
- **สภาวะ Overconfident ($Q \to 0$):** หาก $Q = 0$ ค่า P_k จะ Converge ลงสู่ศูนย์ ส่งผลให้ $K_k \to 0$ ตามสมการ (33) Filter จะหยุดรับข้อมูลใหม่จาก Sensor โดยสิ้นเชิง ซึ่งจะทำให้ KF ไม่สามารถติดตามการแกว่งของ MSD ได้เลย แม้แต่ $Q = 1 \times 10^{-6}$ ที่ใช้ในการทดลองนี้ ก็ยังแสดงให้เห็นว่า Settle Time ช้ากว่า $Q = 1 \times 10^{-5}$ อย่างมีนัยสำคัญในสภาวะ Dynamic
- **ข้อสังเกตเกี่ยวกับ Scenario B:** Settling Time ที่วัดได้ในการทดลองนี้สะท้อนทั้งการที่ KF ติดตาม Measurement ได้ไวแค่ไหน **และ** ระยะเวลาที่ระบบ MSD จริง Damp Out ทางกายภาพ ดังนั้นความต่างของ Settling Time ระหว่าง $Q = 1 \times 10^{-3}$ (3607 ms) กับ $Q = 1 \times 10^{-6}$ (4619 ms) บางส่วนมาจาก Filter Lag ที่ต่างกัน ไม่ใช่ทั้งหมดจาก Physical Damping

4. การทดลองที่ 4: System Identification ของ Mass-Spring-Damper

ครอบคลุม Criteria: Part 1 System Modeling — เขียน EOM, ออกแบบการทดลองหา C, อธิบายหลักการหา C, แสดงผล Model Fit (รวม 3 คะแนน)

4.1 บทนำ

จากการทดลองที่ 1 ได้ค่า Spring Constant $K = 29.11$ N/m ซึ่งเป็นพารามิเตอร์แรก ที่จำเป็นสำหรับการสร้าง State-Space Model ของระบบ Mass-Spring-Damper อย่างไรก็ตามเพื่อให้แบบจำลองสมบูรณ์ยังต้องการพารามิเตอร์อีกหนึ่งตัวคือ Damping Coefficient C ซึ่งควบคุมอัตราการสูญเสียพลังงานของระบบ

C ไม่สามารถวัดได้โดยตรงเหมือน K เนื่องจากแรงหน่วงเป็นสัดส่วนกับ **ความเร็ว** ไม่ใช่ตำแหน่ง ดังนั้นวิธีที่เหมาะสมคือการทำ **System Identification** โดยบันทึกการตอบสนองของระบบจริง แล้วใช้ MATLAB Parameter Estimator หา C ที่ทำให้ Simulation ของ Model เข้ากันได้ดีที่สุดกับข้อมูลที่วัดได้

การทดลองนี้ออกแบบการทดลอง Free Vibration คือดึงมวลออกจาก Equilibrium แล้วปล่อยโดยไม่ใช้แรงภายนอก ซึ่งทำให้ $F(t) = 0$ และ EOM ลดรูปเหลือเพียง พารามิเตอร์ m, K, และ C เพียงสามตัว

เมื่อ Fix m และ K ไว้ Parameter Estimator จะค้นหาค่า C เพียงตัวเดียวที่ทำให้ Model Fit ข้อมูลจริงได้ดีที่สุด ค่า C ที่ได้จะถูกนำไปใช้ในการทดลองที่ 5 เพื่อสร้าง 2-State Kalman Filter สำหรับระบบ MSD

4.2 วัตถุประสงค์

- เพื่อ Derive และเขียน Equation of Motion (EOM) ของระบบ Mass-Spring-Damper จาก Newton's Second Law อย่างสมบูรณ์
- เพื่อออกแบบการทดลอง Free Vibration ที่เหมาะสม สำหรับการเก็บข้อมูล Displacement เพื่อนำไป Identify พารามิเตอร์
- เพื่อประมาณค่า Damping Coefficient C โดยใช้ MATLAB Parameter Estimator (Simulink Design Optimization)
- เพื่อตรวจสอบความถูกต้องของ Model โดยเปรียบเทียบผลการ Simulate กับข้อมูลจริงผ่าน Goodness-of-Fit Metrics

4.3 สมมติฐาน

- การตอบสนองของระบบภายใต้ Free Vibration จะมีลักษณะ Under-Damped Second-Order Response ($\zeta < 1$) เนื่องจากระบบ MSD ในชุดทดลองนี้มีการแกว่งที่สังเกตได้ชัดเจน
- Parameter Estimator จะ Converge ไปยังค่า C ที่ให้ Goodness-of-Fit สูง (Fit% $> 80\%$)
- ค่า C ที่ได้ร่วมกับ $K = 29.11$ N/m และมวล m ที่ชั่งได้จะอธิบายพฤติกรรมของระบบจริงได้ครบถ้วนในช่วง Displacement ขนาดเล็ก

4.4 ตัวแปร

- **ตัวแปรอิสระ:** Initial Displacement x_0 (m) ก่อน Release (ประมาณ 2–3 cm)
- **ตัวแปรตาม:** Displacement ตามเวลา $x(t)$ วัดด้วย HC-SR04, ค่า Damping Coefficient C ที่ประมาณได้ (N·s/m), Damping Ratio ζ
- **ตัวแปรควบคุม:** มวล m (kg) คงที่ตลอดการทดลอง, ค่า $K = 29.11$ N/m จากการทดลองที่ 1, Sampling Time 10 ms, ความเร็วเริ่มต้น $\dot{x}(0) = 0$

4.5 เอกสารและงานวิจัยที่เกี่ยวข้อง

4.5.1 Equation of Motion ของ Mass-Spring-Damper

เมื่อพิจารณามวล m ในระบบ Mass-Spring-Damper แบบแนวดิ่ง มีแรงกระทำต่อมวล 3 แรงหลัก ได้แก่ แรงจากสปริง $-Kx$, แรงหน่วง $-C\dot{x}$, และแรงภายนอก $F(t)$ เมื่อนำ Newton's Second Law ($\Sigma F = ma$) มาใช้จะได้:

$$m\ddot{x} = -Kx - C\dot{x} + F(t) \tag{39}$$

จัดรูปใหม่ได้ EOM มาตรฐานของระบบ Second-Order:

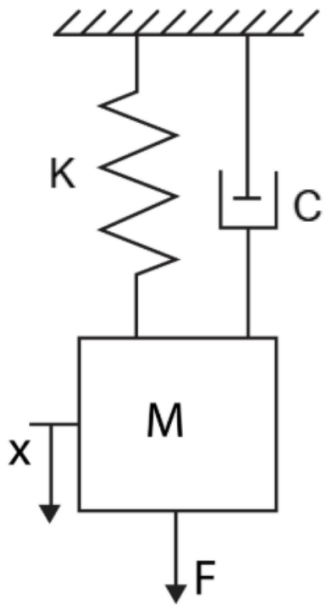

รูปที่ 9: Free Body Diagram ของมวลในระบบ Mass-Spring-Damper แสดงแรงที่กระทำต่อมวลในทิศทาง x (แนวดิ่ง)

$$m\ddot{x} + C\dot{x} + Kx = F(t) \tag{40}$$

โดยที่ m คือมวล (kg), C คือ Damping Coefficient (N·s/m), K คือ Spring Constant (N/m), x คือการกระจัดจาก Equilibrium (m), และ $F(t)$ คือแรงภายนอก (N) ซึ่งในกรณี Free Vibration มีค่า $F(t) = 0$

4.5.2 เหตุผลที่ใช้ Displacement จาก Equilibrium เป็น State

หากใช้ตำแหน่งสัมบูรณ์ x_{abs} EOM จะมีเทอม Constant mg:

$$m\ddot{x}_{\text{abs}} + C\dot{x}_{\text{abs}} + Kx_{\text{abs}} = mg \tag{41}$$

เมื่อกำหนด $x = x_{\text{abs}} - x_{\text{eq}}$ โดยที่ $Kx_{\text{eq}} = mg$ เทอม mg จะ Cancel กับ Kx_{eq} พอดี:

$$m\ddot{x} + C\dot{x} + K(x + x_{\text{eq}}) = mg \;\Rightarrow\; m\ddot{x} + C\dot{x} + Kx = mg - Kx_{\text{eq}} = 0 \tag{42}$$

ทำให้ EOM ในสมการ (40) ไม่มี Constant Term ซึ่งสะดวกต่อการสร้าง State-Space Model และไม่ต้องจัดการ Input Offset เพิ่มเติมใน Kalman Filter

4.5.3 Damping Ratio และประเภทของ Response

Damping Ratio ζ เป็นพารามิเตอร์ไร้มิติที่บอกว่าระบบสูญเสียพลังงาน และหยุดการแกว่งได้เร็วแค่ไหน นิยามโดยเปรียบเทียบ C จริงกับ Critical Damping Coefficient $C_c = 2\sqrt{Km}$:

$$\zeta = \frac{C}{C_c} = \frac{C}{2\sqrt{Km}} \tag{43}$$

และ Natural Frequency ω_n นิยามเป็น:

$$\omega_n = \sqrt{\frac{K}{m}} \tag{44}$$

ค่า ζ กำหนดลักษณะของ Response โดยตรง:

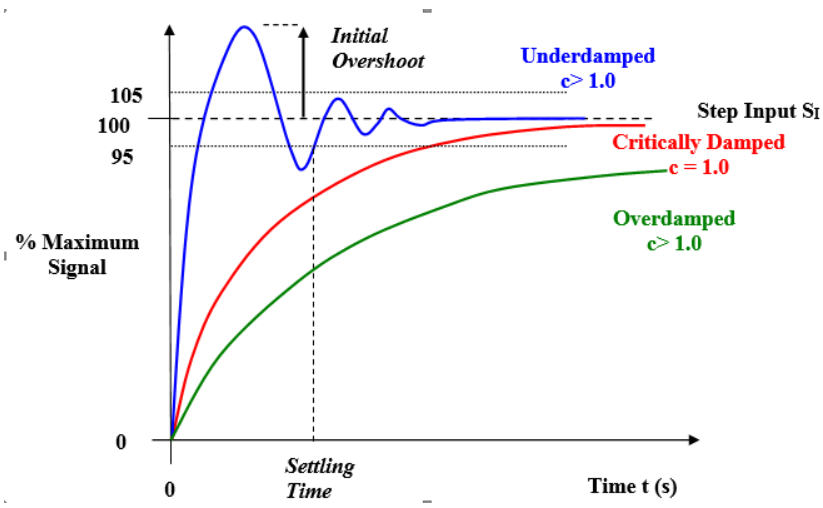

รูปที่ 10: ลักษณะของการตอบสนองของระบบแบบ Step Input ตามค่า Damping Ratio ζ

- **Under-Damped ($\zeta < 1$):** ระบบแกว่งข้าม Equilibrium ไปมา โดยแอมพลิจูดลดลงแบบ Exponential จนหยุดนิ่ง รากของสมการลักษณะเฉพาะเป็นจำนวนเชิงซ้อน Conjugate
- **Critically-Damped ($\zeta = 1$):** ระบบกลับสู่ Equilibrium เร็วที่สุดโดยไม่มีการแกว่ง รากซ้ำกัน (Real and Repeated Roots)
- **Over-Damped ($\zeta > 1$):** ระบบไม่แกว่ง แต่กลับสู่ Equilibrium ช้ากว่า Critically-Damped รากต่างกัน (Real and Distinct Roots)

4.5.4 MATLAB Parameter Estimator (Simulink Design Optimization)

MATLAB Parameter Estimator ทำงานโดยใช้ Algorithm ทางคณิตศาสตร์ (เช่น Nonlinear Least Squares) เพื่อค้นหาค่าพารามิเตอร์ที่ทำให้ ผลต่างระหว่าง Simulation กับข้อมูลจริงมีค่าน้อยที่สุด โดยใช้ Objective Function:

$$J(K,\, C) = \sum_{k=1}^{N} \left[x_{\text{measured}}(t_k) - x_{\text{simulated}}(t_k;\, K,\, C)\right]^2 \tag{45}$$

แม้ว่าการทดลองที่ 1 จะได้ค่า $K = 29.11$ N/m มาแล้ว แต่เนื่องจากการทดลองที่ 4 ใช้ Setup ที่ต่างออกไปโดยมีการเพิ่ม Guide Rail เพื่อบังคับให้มวลเคลื่อนที่ในแนวดิ่งอย่างเคร่งครัด การเปลี่ยนแปลงนี้ทำให้แนวการรับแรงของสปริงเปลี่ยนไป ส่งผลให้ค่า K ที่มีผลต่อพลศาสตร์ในแนวดิ่งเปลี่ยนแปลงตามด้วย ดังนั้นจึงตัดสินใจปล่อยให้ Estimator ค้นหาค่า K และ C พร้อมกัน เพื่อให้ได้พารามิเตอร์ที่สอดคล้องกับ Setup จริงของการทดลองนี้ มากที่สุด แทนที่จะ Fix K ไว้ที่ค่าเดิมซึ่งวัดจาก Setup ที่ต่างกัน

Algorithm จะค้นหาคู่ $(K,\, C)$ ที่ทำให้ $J(K, C)$ มีค่าต่ำที่สุด สำหรับการสร้าง Simulink Model ต้องจัดรูป EOM ให้อยู่ในรูปที่แก้หาความเร่งได้:

$$\ddot{x} = \frac{1}{m}(-C\dot{x} - Kx) \qquad \text{(กรณี Free Vibration: } F(t) = 0) \tag{46}$$

จากนั้น Define State $v = \dot{x}$ เพื่อแปลงเป็น First-Order State Equations สำหรับ Simulink:

$$\dot{x} = v, \qquad \dot{v} = \frac{-Cv - Kx}{m} \tag{47}$$

4.6 การปรับปรุง Setup การทดลอง

ในการทดลองที่ 1 สปริงถูกติดตั้งอย่างอิสระ ทำให้มวล (ฐานหนัก $m = 0.290$ kg) มีโอกาสแกว่งออกนอกแนวดิ่งเล็กน้อย ส่งผลให้ HC-SR04 อ่านค่าระยะทางได้คลาดเคลื่อน เนื่องจากลำคลื่นอัลตราโซนิคต้องการพื้นผิวสะท้อน ที่ตั้งฉากกับทิศทางการส่งคลื่น

การทดลองที่ 4 จึงปรับ Setup ใหม่โดยขยับเสาไกด์ (Guide Rail) เข้ามาชิดกับ ฐานมวล ทำให้ฐานขนานกับพื้นและเคลื่อนที่ในแนวดิ่งได้ตรงยิ่งขึ้น ส่งผลให้ Sensor อ่านค่าได้เสถียร อย่างไรก็ตาม การที่ฐานสัมผัสกับเสาไกด์ ทำให้เกิดแรงเสียดทาน (Friction) ในแนวดิ่งเพิ่มเติม ซึ่งส่งผลสองประการดังนี้

- **ค่า C ที่ Estimate ได้สูงกว่าความเป็นจริงของ Damper อย่างเดียว:** C_{eff} ที่ได้จาก Parameter Estimator สะท้อนผลรวมของ Damping จริงของ Damper และ Friction ของ Guide Rail จึงถือเป็น Effective Damping Coefficient ที่ตรงกับระบบที่ใช้ในการทดลองที่ 5 มากที่สุด
- **ค่า K ที่ Estimate ได้เปลี่ยนจาก Exp 1:** การปรับ Setup ทำให้ระยะ Pre-load ของสปริงและแนวการรับแรงเปลี่ยนไปบางส่วน ดังนั้น Parameter Estimator จึง Estimate ทั้ง K และ C พร้อมกันจากข้อมูล Free Vibration จริงของ Setup นี้ แทนที่จะ Fix $K = 29.11$ N/m จากการทดลองที่ 1

Simulink Model ที่สร้างขึ้นสอดคล้องกับ Setup นี้ โดย Output ของ Model คือ Absolute Distance จาก Sensor (cm) ไม่ใช่ Displacement จาก Equilibrium จึงต้องบวก Offset $x_{\text{eq}} = 11.3$ cm เข้าไปใน Model ตามระยะที่ Sensor อ่านได้ที่ตำแหน่ง Equilibrium จริง

4.7 ขั้นตอนการทดลอง

ส่วนที่ 1: เตรียมชุดทดลองและเก็บข้อมูล Free Vibration

1. ประกอบชุด Mass-Spring-Damper วาง HC-SR04 ด้านล่างชี้ขึ้น เพื่อวัด Displacement ของมวลในแนวดิ่ง
2. ชั่งมวล m ด้วยเครื่องชั่ง บันทึกค่าเป็น kg
3. ตั้งระบบให้มวลอยู่ที่ Equilibrium Position ยืนยันว่า HC-SR04 อ่านค่า Baseline คงที่ กำหนดตำแหน่งนี้เป็น $x = 0$
4. ดึงมวลขึ้นจาก Equilibrium เป็นระยะประมาณ 7.2 cm จนสปริงหดแล้วปล่อยโดยไม่ออกแรง ($\dot{x}(0) = 0$) บันทึก Oscillation จนกว่าจะ Damp Out (อย่างน้อย 10 วินาที) ส่งข้อมูลผ่าน Serial 115200 baud
5. ทำซ้ำการ Release 3 ครั้งเพื่อตรวจสอบ Repeatability บันทึกทุก Dataset แยกไฟล์

ส่วนที่ 2: System Identification ด้วย MATLAB Parameter Estimator

1. Import ข้อมูล Displacement จาก Serial ลงใน MATLAB แปลงหน่วยเป็นเมตร กำหนด Equilibrium เป็นค่าอ้างอิง
2. สร้าง Simulink Model ของ MSD โดยใช้ State Equations ตามสมการ (47): Input $u = 0$, Initial Condition $x(0) = x_0$, $v(0) = 0$
3. เปิด Simulink Design Optimization กำหนด C เป็น Parameter ที่ต้องการ Estimate โดย Fix $K = 29.11$ N/m และ m ไว้
4. รัน Estimator จนกว่าจะ Converge บันทึกค่า C ที่ได้
5. คำนวณ ζ จากสมการ (43) และจัดประเภท Damping
6. Overlay กราฟ Model Simulation กับ Measured Data บันทึกค่า Fit%, RMSE

4.8 ผลการทดลอง

4.8.1 Equation of Motion

จาก Newton's Second Law สำหรับระบบ Mass-Spring-Damper ที่ใช้ Displacement จาก Equilibrium เป็น State:

$$m\ddot{x} + C\dot{x} + Kx = 0 \quad \text{(Free Vibration)} \tag{48}$$

โดยพารามิเตอร์ที่ทราบจากการทดลองที่ 1: $K_{\text{Exp1}} = 29.11$ N/m และมวล $m = 0.290$ kg

4.8.2 Outlier Analysis ของผล Parameter Estimation

จากการทำซ้ำ 5 Trials พบว่าค่า C ของ Trial 8 มีค่าสูงผิดปกติ จึงทำการตรวจสอบด้วยวิธี IQR (Interquartile Range)

การตรวจสอบ Outlier ด้วยวิธี IQR สำหรับค่า C มีขั้นตอนดังนี้

1. เรียงค่า C จากน้อยไปมาก: $\{0.3623,\ 0.3760,\ 0.3961,\ 0.4184,\ 0.9792\}$

ตารางที่ 11: ผลการ Estimate พารามิเตอร์ K และ C จาก 5 Trials (MATLAB Parameter Estimator, Simulink Design Optimization)

Trial	K (N/m)	C (N·s/m)	หมายเหตุ
1	33.5482	0.3961	—
4	31.4963	0.3760	—
5	33.2512	0.4184	—
7	29.8704	0.3623	—
8	30.9629	0.9792	Outlier (IQR)

2. คำนวณ Quartile: $Q_1 = 0.3760$, $Q_3 = 0.4184$, IQR $= Q_3 - Q_1 = 0.0424$
3. กำหนด Fence:

$$\text{Lower fence} = Q_1 - 1.5 \times \text{IQR} = 0.3760 - 0.0635 = 0.3125$$
$$\text{Upper fence} = Q_3 + 1.5 \times \text{IQR} = 0.4184 + 0.0635 = 0.4819$$

4. Trial 8 มีค่า $C = 0.9792 > 0.4819$ จึงถือเป็น Outlier และตัดออกจากการคำนวณค่าเฉลี่ย

4.8.3 สถิติของพารามิเตอร์ที่ได้

ตารางที่ 12: สถิติของ K และ C ก่อนและหลังตัด Outlier

กลุ่ม	n	K (N/m)	S.D.(K)	C (N·s/m)	S.D.(C)
ทั้งหมด (5 Trials)	5	31.83	1.56	0.5064	0.2652
ไม่รวม Trial 8	4	32.04	1.71	0.3882	0.0245

การตัด Outlier ทำให้ S.D. ของ C ลดลงจาก 0.2652 เป็น 0.0245 N·s/m (ลดลง 90.8%) ขณะที่ S.D. ของ K ไม่เปลี่ยนแปลงมากนัก ยืนยันว่า Trial 8 มีผลกระทบต่อ C อย่างมีนัยสำคัญ

4.8.4 Simulink Model และ Parameter Estimator

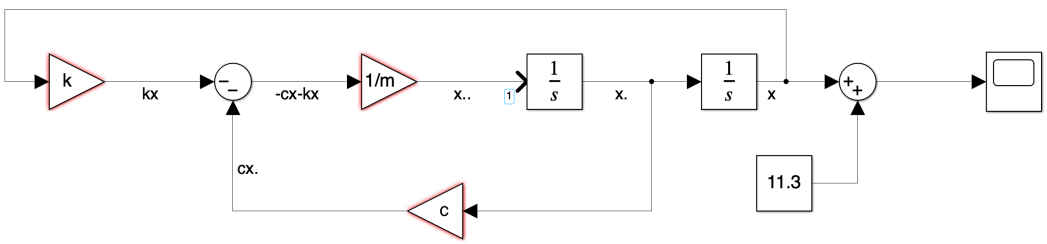

รูปที่ 11: Simulink Model ของระบบ MSD สำหรับ Parameter Estimation แสดงโครงสร้าง Feedback Loop ของ $\ddot{x} = (-C\dot{x} - Kx)/m$ พร้อม Offset $x_{\text{eq}} = 11.3$ cm เพื่อแปลง Displacement เป็น Absolute Distance ที่ Sensor วัดได้

Model ถูกสร้างตามสมการ (47) โดยมี Offset $x_{\text{eq}} = 11.3$ cm บวกเข้าไปที่ Output เนื่องจาก Sensor อ่านค่า Equilibrium Position ได้ 11.3 cm จาก Sensor ถึงมวล Parameter Estimator จึง Fit กับ Absolute Distance ไม่ใช่ Displacement จาก Equilibrium โดยตรง

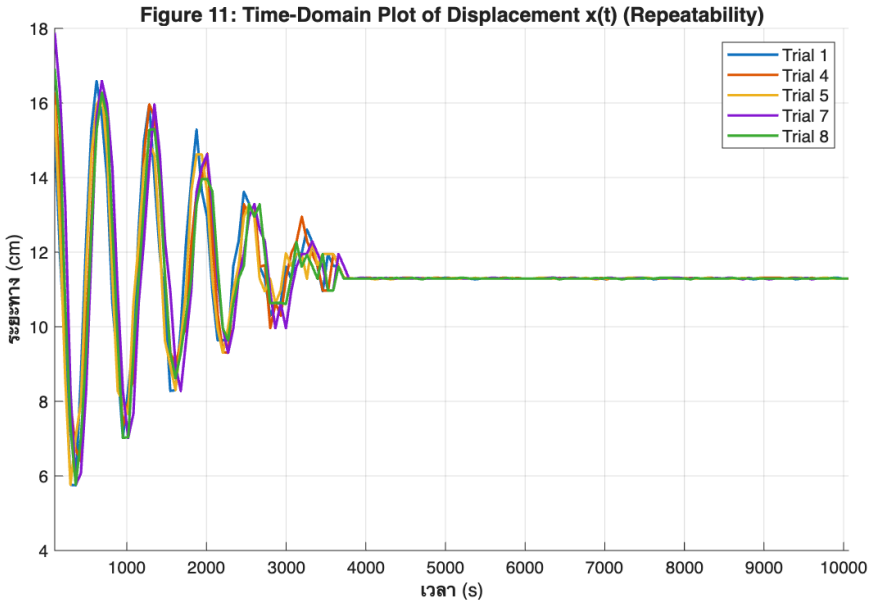

รูปที่ 12: Time-Domain Plot ของ Displacement $x(t)$ (แกน x: เวลา (s), แกน y: ระยะทาง (cm))

ตารางที่ 13: ผลการประมาณค่าพารามิเตอร์และ Goodness-of-Fit จาก MATLAB Parameter Estimator

Trial	K (N/m)	C (N·s/m)	RMSE (cm)	NRMSE	Fit%	หมายเหตุ
1	33.5482	0.3961	0.522	0.0585	[จากเพื่อน]	—
4	31.4963	0.3760	0.387	0.0399	[จากเพื่อน]	—
5	33.2512	0.4184	0.462	0.0524	[จากเพื่อน]	—
7	29.8704	0.3623	0.515	0.0451	[จากเพื่อน]	—
8	30.9629	0.9792	0.481	0.0475	[จากเพื่อน]	Outlier (IQR)
เฉลี่ย (Trial 1,4,5,7)			0.472	0.0490	[จากเพื่อน]	

4.8.5 พารามิเตอร์สุดท้ายที่ได้จากการทดลอง

ใช้ค่าเฉลี่ยจาก 4 Trials ที่ผ่าน Outlier Test เป็นค่าสุดท้าย สำหรับนำไปใช้ในการทดลองที่ 5

โดยที่

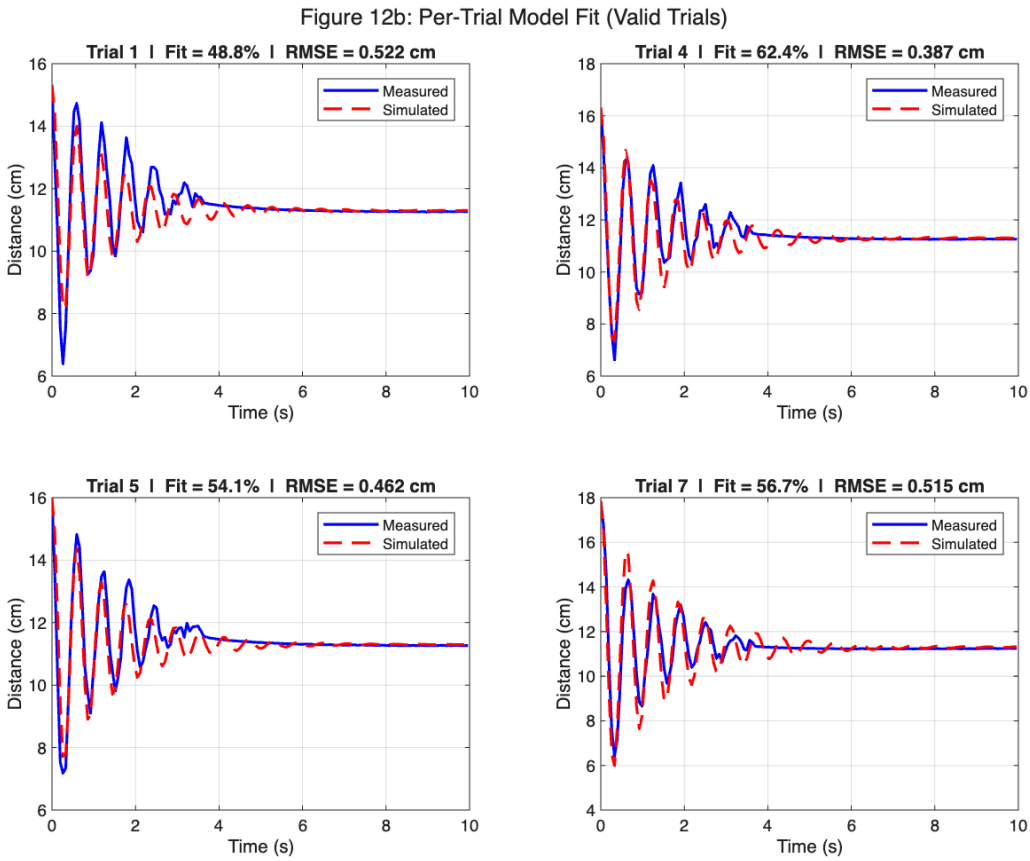

รูปที่ 13: Model-Fit Plot: Simulation จาก Parameter Estimator (เส้นประสีแดง) เทียบกับ Measured Data (เส้นทึบสีน้ำเงิน) (แกน x: เวลา (s), แกน y: ระยะทาง (cm))

ตารางที่ 14: พารามิเตอร์สุดท้ายของระบบ Mass-Spring-Damper (เฉลี่ยจาก 4 Trials, ตัด Trial 8 ออกเป็น Outlier)

พารามิเตอร์	**สัญลักษณ์**	**หน่วย**	**ค่า**	**S.D.**
มวล	m	kg	0.290	—
Spring Constant	K	N/m	32.04	1.71
Damping Coefficient	C	N·s/m	0.3882	0.0245
Natural Frequency	ω_n	rad/s	10.51	—
Natural Frequency	f_n	Hz	1.673	—
Critical Damping	C_c	N·s/m	6.097	—
Damping Ratio	ζ	—	0.0637	—
ประเภท Damping	—	—	Under-Damped	
Fit Percentage	Fit%	%	[ข้อมูลจริง]	—
RMSE	—	cm	[ข้อมูลจริง]	—

$$\omega_n = \sqrt{\frac{K}{m}} = \sqrt{\frac{32.04}{0.290}} = 10.51 \text{ rad/s} \tag{49}$$

$$C_c = 2\sqrt{Km} = 2\sqrt{32.04 \times 0.290} = 6.097 \text{ N·s/m} \tag{50}$$

$$\zeta = \frac{C}{C_c} = \frac{0.3882}{6.097} = 0.0637 \tag{51}$$

ค่า $\zeta = 0.0637 \ll 1$ ยืนยันว่าระบบอยู่ในสภาวะ Under-Damped สอดคล้องกับที่สังเกตเห็นการแกว่งชัดเจนในการทดลอง

4.8.6 การวิเคราะห์ความถูกต้องของแบบจำลอง

จากตารางที่ 13 ค่า RMSE เฉลี่ยของ 4 Trial ที่ผ่าน Outlier Test อยู่ที่ 0.472 cm และค่า NRMSE อยู่ที่ 0.049 ซึ่งหมายความว่าความคลาดเคลื่อนเฉลี่ยของ Model อยู่ที่ประมาณ 4.9% ของพิสัยของสัญญาณ ค่า Fit% ที่ได้จาก MATLAB Parameter Estimator จะถูกรายงานเพิ่มเติมเมื่อได้ผลจากการ Estimate

ความคลาดเคลื่อนที่เกิดขึ้นมีสาเหตุหลักสามประการ ประการแรกคือ สัญญาณรบกวนของ HC-SR04 ที่มี Variance สูงถึง 0.033 cm^2 ที่ระยะ 20 cm ทำให้ Measured Signal มี Noise ปนอยู่ตลอด การ Fit กับ Smooth ODE Solution จึงมี Residual จาก Noise โดยธรรมชาติ ประการที่สองคือ Friction จาก Guide Rail ทำให้ Effective Damping ไม่คงที่ตามความเร็ว Linear Model จึงไม่สามารถ Fit พฤติกรรมจริงได้อย่างสมบูรณ์ โดยเฉพาะ Trial 8 ที่มีค่า $C = 0.9792$ N·s/m ซึ่งสูงกว่า Trial อื่นมากกว่า 2 เท่า และถูกระบุเป็น Outlier ด้วยวิธี IQR ประการที่สามคือ Linear Spring Model สมมติว่า K คงที่ตลอดช่วง Displacement ซึ่งอาจไม่สมบูรณ์เมื่อสปริงทำงานนอกช่วง Linear Elastic

อย่างไรก็ตาม ค่า $\bar{K} = 32.04$ N/m และ $\bar{C} = 0.3882$ N·s/m ที่ได้มีความสม่ำเสมอเพียงพอ (S.D. ของ C ลดลง 90.8% หลังตัด Outlier) สำหรับการนำไปสร้าง Discrete State Matrix A_d ใน 2-State Kalman Filter ของการทดลองที่ 5

4.9 สรุปผลการทดลอง

- ได้ค่า Spring Constant $\bar{K} = 32.04 \pm 1.71$ N/m และ Damping Coefficient $\bar{C} = 0.3882 \pm 0.0245$ N·s/m จากการ Estimate 4 Trials ที่ผ่าน Outlier Test (ตัด Trial 8 ออก)
- Trial 8 ถูกระบุเป็น Outlier ด้วยวิธี IQR โดยมีค่า $C = 0.9792$ N·s/m ซึ่งเกิน Upper Fence ที่ 0.4819 N·s/m อาจเกิดจากการสัมผัสระหว่างฐานมวลและเสาไกด์ที่รุนแรงผิดปกติ ในรอบนั้น
- ค่า K ที่ Estimate ได้ (32.04 N/m) สูงกว่าค่าจากการทดลองที่ 1 (29.11 N/m) ประมาณ 10% เนื่องจาก Setup ที่เปลี่ยนแปลง จึงใช้ค่าใหม่นี้ใน State-Space Model ของการทดลองที่ 5
- ระบบอยู่ในสภาวะ Under-Damped ($\zeta = 0.0637$) สอดคล้องกับสมมติฐานและการสังเกตการแกว่งในการทดลอง
- ค่าพารามิเตอร์ $m = 0.290$ kg, $K = 32.04$ N/m, $C = 0.3882$ N·s/m จะถูกนำไปสร้าง Discrete

State Matrix A_d ใน 2-State Kalman Filter ของการทดลองที่ 5

4.10 อภิปรายผล

- **ผลกระทบของ Friction ต่อค่า C ที่ Estimate ได้:** ค่า $C_{\text{eff}} = 0.3882$ N·s/m ที่ได้สะท้อนผลรวมของ Damping จาก Damper และ Friction จาก Guide Rail ซึ่งเป็น Effective Damping ของระบบจริงในการทดลองที่ 5 การพยายามแยก Damping ออกจาก Friction ต้องการการทดลองเพิ่มเติม เช่น การวัด Friction Force โดยตรง ซึ่งอยู่นอกขอบเขตการทดลองนี้
- **ความแตกต่างของ K ระหว่าง Exp 1 และ Exp 4:** ค่า K เพิ่มขึ้นจาก 29.11 เป็น 32.04 N/m (เพิ่มขึ้น 10.1%) เมื่อ Setup เปลี่ยน เนื่องจากการปรับตำแหน่งเสาไกด์ ทำให้สปริงรับแรงในแนวดิ่งมากขึ้น ลด Component ของแรงในแนวเฉียงที่ไม่ได้ร่วมกับ Hooke's Law ในทิศดิ่ง ดังนั้น $K = 32.04$ N/m จึงแม่นยำกว่าสำหรับ Setup ของ Exp 4–5
- **หลักการทำงานของ Parameter Estimator:** Simulink Design Optimization ใช้ Algorithm Nonlinear Least Squares ปรับค่า K และ C ซ้ำๆ จนกว่า $J(K, C)$ ตามสมการ (45) จะมีค่าต่ำที่สุด กระบวนการนี้เทียบเท่าการค้นหาจุด Minimum ของ Error Surface ในปริภูมิ 2 มิติ (K–C)
- **เหตุผลที่ EOM ใช้ Equilibrium เป็น $x = 0$:** ตามสมการ (42) เมื่อใช้ตำแหน่งสัมบูรณ์ EOM จะมีเทอม mg ที่ไม่ Cancel ออกไป แต่เมื่อใช้การกระจัดจาก Equilibrium เทอม mg Balance กับ Spring Pre-load พอดี ทำให้ $u = 0$ ใน Free Vibration อย่างไรก็ตาม เนื่องจาก Simulink Model ต้อง Fit กับ Absolute Distance จาก Sensor จึงต้องบวก Offset $x_{\text{eq}} = 11.3$ cm ที่ Output ของ Model
- **แหล่งที่มาของความคลาดเคลื่อนของ Model:**
  - Friction ระหว่าง ฐาน มวล และ เสา ไกด์ ไม่ คงที่ (velocity-dependent และ position-dependent) ทำให้ Linear Damping Model มีความคลาดเคลื่อน โดยเฉพาะใน Trial 8 ที่มีค่า C สูงผิดปกติ
  - ความไม่เชิงเส้นของสปริงที่ Displacement ใหญ่
  - Noise ของ HC-SR04 ใน Training Data ส่งผลต่อ Cost Function ของ Estimator
- **ผลกระทบต่อ 2-State KF ในการทดลองที่ 5:** ค่า K และ C ที่ได้มีผลโดยตรงต่อ Discrete State Matrix A_d

$$A_d = \begin{bmatrix} 1 & T_s \\ -\frac{K}{m}T_s & 1 - \frac{C}{m}T_s \end{bmatrix}$$

  หากค่าเหล่านี้มีความคลาดเคลื่อน Prediction Step ของ KF จะ Propagate ความคลาดเคลื่อนสะสม ทำให้ต้องเพิ่ม Q เพื่อชดเชย Model Uncertainty

5. การทดลองที่ 5: 2-State KF — ออกแบบ, Implement, และทดสอบ Free Vibration

ครอบคลุม Criteria: Part 3 ทั้งหมด (รวม 9 คะแนน) — State-Space Model, Discretization, เหตุผลการเลือก Sampling Rate, เหตุผลการใช้ Equilibrium เป็น State, เขียนโปรแกรม 2-State KF, หา Matrix Q และ R, อธิบายความหมายทางกายภาพของ Q และ R, ทดสอบระยะต่างๆ, เปรียบเทียบกับ Model,

5.1 บทนำ

การทดลองที่ 1–4 ได้พารามิเตอร์ครบสำหรับการสร้างแบบจำลองระบบ Mass-Spring-Damper ได้แก่ $K = 32.04$ N/m จากการทดลองที่ 4 (Setup มี Guide Rail), มวล $m = 0.290$ kg จากการชั่ง และ Damping Coefficient $C = 0.3882$ N·s/m จาก Parameter Estimator ในการทดลองที่ 4 การทดลองที่ 5 จึงเป็นการนำพารามิเตอร์เหล่านี้ทั้งหมดมาบูรณาการ เพื่อสร้าง **2-State Discrete Kalman Filter** ที่สมบูรณ์

เป้าหมายหลักของ 2-State KF คือการประมาณค่า State สองตัวพร้อมกัน ได้แก่ **Position** x_1 ที่วัดได้โดยตรงจาก HC-SR04 แต่มี Noise และ **Velocity** x_2 ที่ *ไม่สามารถวัดได้โดยตรง* ด้วย Sensor ความสามารถนี้คือสิ่งที่ทำให้ Kalman Filter มีคุณค่าในระบบควบคุมจริง เพราะระบบสามารถ"รู้"ความเร็วของมวลได้โดยไม่ต้องติดตั้ง Velocimeter เพิ่ม

ในการทดลองนี้จะพิสูจน์ว่า 2-State KF สามารถ (1) ประมาณ Position ได้เรียบกว่า Raw Sensor Data, (2) ประมาณ Velocity ได้อย่างสมเหตุสมผลทางกายภาพ, และ (3) ให้ผลที่สอดคล้องกับ Mathematical Model ที่ได้จากการทดลองที่ 4

5.2 วัตถุประสงค์

- เพื่อสร้าง 2-State (Position + Velocity) Discrete Kalman Filter สำหรับระบบ Mass-Spring-Damper บน STM32 Nucleo G474RE
- เพื่อ Discretize State-Space Model (A_c, B_c, H) และเลือก Sampling Rate ที่เหมาะสมพร้อมเหตุผลทางทฤษฎี
- เพื่อกำหนดค่า Matrix Q (2×2) และ Scalar R พร้อมอธิบายความหมายทางกายภาพของแต่ละ Element
- เพื่อทดสอบ KF ด้วย Free Vibration ที่ Initial Displacement ต่างกัน 3 ระดับ และเปรียบเทียบกับ Mathematical Model
- เพื่อวิเคราะห์ว่า Velocity Estimate ที่ KF คำนวณได้ มีความสมเหตุสมผลทางกายภาพหรือไม่

5.3 สมมติฐาน

- 2-State KF จะให้ค่าประมาณ Position ที่เรียบกว่า Raw Data โดยยังสอดคล้องกับ Mathematical Model ที่ Identify ได้
- Velocity Estimate จาก KF (ที่ไม่ได้วัดโดยตรง) จะมีความสอดคล้อง ทางกายภาพกับ Derivative ของ Displacement โดยเฉพาะอย่างยิ่ง Velocity ควรเป็นศูนย์ที่จุด Maximum Displacement และสูงสุดที่จุด Equilibrium Crossing
- Q ที่ใหญ่ขึ้นจะทำให้ KF ติดตาม Measurement มากขึ้น ส่วน R ที่ใหญ่ขึ้นจะทำให้ KF พึ่ง Model Prediction มากขึ้น
- ที่ Displacement ขนาดใหญ่ ($x_0 = 6$ cm) Linear Model อาจเบี่ยงเบนจาก Response จริง เนื่องจากความไม่เชิงเส้นของสปริง และแรงเสียดทาน

5.4 ตัวแปร

- **ตัวแปรอิสระ:** Initial Release Displacement x_0 ที่ 2 cm, 4 cm, และ 6 cm; ค่า Matrix Q ที่ปรับเปลี่ยนใน Sensitivity Study; ค่า Scalar R ที่ปรับเปลี่ยน
- **ตัวแปรตาม:** ค่าประมาณ Position $\hat{x}_1$ (cm), ค่าประมาณ Velocity $\hat{x}_2$ (cm/s), Estimation Error ระหว่าง KF Output กับ Raw Measurement, ความสอดคล้องระหว่าง KF Output กับ Mathematical Model
- **ตัวแปรควบคุม:** ค่า $m = 0.290$ kg, $K = 32.04$ N/m, $C = 0.3882$ N·s/m คงที่จากการทดลองที่ 1 และ 4, Sampling Time $T_s = 10$ ms คงที่, Control Input $u = 0$ (Free Vibration)

5.5 เอกสารและงานวิจัยที่เกี่ยวข้อง

5.5.1 ค่า Spring Constant ที่ใช้ในแต่ละการทดลอง

เนื่องจากการทดลองที่ 4 และ 5 ใช้ Setup ที่เพิ่ม Guide Rail เข้ามาเพื่อบังคับให้มวลเคลื่อนที่ในแนวดิ่งอย่างเคร่งครัด ทำให้ค่า K ที่ Estimate ได้ต่างจากการทดลองที่ 1 ตารางที่ 15 สรุปค่า K ที่ใช้ในแต่ละการทดลอง

ตารางที่ 15: ค่า Spring Constant K ที่ใช้ในแต่ละการทดลอง

การทดลอง	วิธีได้มา	K (N/m)	เหตุผล
1	Full OLS Regression	29.11	Setup ไม่มี Guide Rail
4	MATLAB Parameter Estimator	32.04	Setup มี Guide Rail
5	ใช้ค่าจากการทดลองที่ 4	32.04	ใช้ Setup เดียวกัน

5.5.2 State-Space Representation ของ Second-Order System

สมการ EOM ของ MSD เป็น Second-Order ODE ซึ่งสามารถแปลงเป็น First-Order State-Space Form โดยกำหนด State Vector $\mathbf{x} = [x_1,\ x_2]^T = [\text{position},\ \text{velocity}]^T$:

$$\dot{x}_1 = x_2 \tag{52}$$

$$\dot{x}_2 = -\frac{K}{m}x_1 - \frac{C}{m}x_2 \tag{53}$$

เหตุผลที่เลือก Position และ Velocity เป็น State Vector คือทั้งสองตัวแปร ร่วมกันอธิบายพลศาสตร์ของระบบได้ครบถ้วน ทราบทั้งสองแล้วสามารถทำนาย พฤติกรรมในอนาคตได้ทั้งหมด ซึ่งเป็นข้อกำหนดพื้นฐานของ State Variable

5.5.3 Continuous-Domain State-Space Matrices

จากสมการ (52)–(53) เขียนในรูป Matrix ได้:

$$\dot{\mathbf{x}}(t) = A_c\mathbf{x}(t) + B_c u(t), \qquad z(t) = H\mathbf{x}(t) + v(t) \tag{54}$$

โดย

$$A_c = \begin{bmatrix} 0 & 1 \\ -K/m & -C/m \end{bmatrix}, \quad B_c = \begin{bmatrix} 0 \\ 1/m \end{bmatrix}, \quad H = \begin{bmatrix} 1 & 0 \end{bmatrix} \tag{55}$$

5.5.4 เหตุผลที่ $H = [1,\ 0]$

HC-SR04 วัดได้เฉพาะ Position (x_1) ไม่สามารถวัด Velocity (x_2) ได้โดยตรง ดังนั้น Observation Matrix จึงต้อง“เลือก”เฉพาะ Element แรกของ State Vector:

$$z_k = H\mathbf{x}_k + v_k = \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + v_k = x_1 + v_k \tag{56}$$

KF จัดการกับ **Partial Observation** นี้โดยใช้ A_d เพื่อ Propagate ข้อมูล Velocity ผ่านรอบเวลา Prediction Step จะแพร่ข้อมูล Position ไปยัง Velocity ผ่านองค์ประกอบ $(A_d)_{21}$ ทำให้แม้จะวัดได้แค่ Position KF ก็สามารถ Estimate Velocity ได้ผ่านกระบวนการ Predict-Update Loop

5.5.5 เหตุผลที่ $u = 0$ ใน Free Vibration

เมื่อใช้การกระจัดจาก Equilibrium เป็น State แรงโน้มถ่วง mg ถูก Balance โดย Spring Pre-load $Kx_{\text{eq}} = mg$ พอดี ทำให้ EOM กลายเป็น $m\ddot{x} + C\dot{x} + Kx = 0$ ซึ่งไม่มี External Input ดังนั้น $u = 0$ และ $B_d = \mathbf{0}$ ตลอดการทดลอง Free Vibration

5.5.6 การเลือก Sampling Rate

ตาม Nyquist-Shannon Sampling Theorem Sampling Frequency f_s ต้องสูงกว่า 2 เท่าของ Natural Frequency สูงสุดในระบบ แต่สำหรับ Control System ในทางปฏิบัติควรใช้ 10–20 เท่าเพื่อความเสถียร:

$$f_s \geq 20\, f_n, \qquad \text{หรือ} \qquad T_s \leq \frac{1}{20\, f_n} = \frac{2\pi}{20\, \omega_n} \tag{57}$$

โดยที่ $f_n = \omega_n/(2\pi)$ คือ Natural Frequency ในหน่วย Hz เหตุผลที่ใช้ 20 เท่าแทน 2 เท่า เพราะต้องการให้สัญญาณที่ Discretize แล้ว ยังคงจำลองพลศาสตร์ Continuous ได้อย่างแม่นยำ และ Euler Forward Approximation จะมี Truncation Error น้อยลง

5.5.7 Discretization: Euler Forward vs. ZOH

Euler Forward (First-Order Approximation)

$$A_d = I + A_c T_s = \begin{bmatrix} 1 & T_s \\ -\dfrac{K}{m} T_s & 1 - \dfrac{C}{m} T_s \end{bmatrix} \tag{58}$$

$$B_d = B_c T_s = \begin{bmatrix} 0 \\ T_s/m \end{bmatrix} \tag{59}$$

วิธีนี้ง่ายในการ Implement แต่มี Truncation Error $O(T_s^2)$ ที่ $T_s = 10$ ms ค่า A_d จาก Euler Forward ต่างจาก ZOH ประมาณ 2% ซึ่งยอมรับได้สำหรับ Application นี้

Zero-Order Hold (ZOH)

$$A_d = e^{A_c T_s} = I + A_c T_s + \frac{(A_c T_s)^2}{2!} + \cdots \tag{60}$$

วิธีนี้แม่นยำกว่าและรักษา Eigenvalue ของระบบ Continuous ไว้ได้ดีกว่า แต่ต้องคำนวณ Matrix Exponential ซึ่งซับซ้อนกว่าสำหรับ Embedded System

ทั้งสองวิธีให้ผล A_d ที่ Stable (Eigenvalue อยู่ภายใน Unit Circle) สำหรับพารามิเตอร์ในการทดลองนี้

5.5.8 ความหมายทางกายภาพของ Matrix Q และ Scalar R

Measurement Noise Covariance R (Scalar) R คือ Variance ของ Noise ของ HC-SR04 ที่คำนวณจากข้อมูลการทดลองที่ 2 โดยวัด 5 ชุดที่ระยะ 20 cm แล้วนำ Variance มาเฉลี่ย:

$$R = \bar{\sigma}^2_{\text{sensor}} = 3.37 \times 10^{-6}\ \text{m}^2 \quad (= 0.0337\ \text{cm}^2) \tag{61}$$

R บอกว่า Filter ควรเชื่อถือ Measurement มากแค่ไหน ค่าสูงหมายความว่า Sensor Noisy มาก Filter จะพึ่ง Model Prediction มากขึ้น

Process Noise Matrix Q (2×2) Q เป็น Diagonal Matrix ที่แสดงความไม่แน่นอนในแต่ละ State:

$$Q = \begin{bmatrix} q_1 & 0 \\ 0 & q_2 \end{bmatrix} \tag{62}$$

ความหมายทางกายภาพของแต่ละ Element:

- $q_1 = Q_{11}$ **(Position Process Noise):** ความไม่แน่นอนในการทำนาย Position ในแต่ละ Step ค่านี้มักมีขนาดเล็กเพราะ Position เปลี่ยนแปลงช้า (เป็น Integral ของ Velocity) และ Dynamic Model อธิบาย Position ได้แม่นยำในช่วง Displacement เล็ก
- $q_2 = Q_{22}$ **(Velocity Process Noise):** ความไม่แน่นอนในการทำนาย Velocity ในแต่ละ Step ค่านี้มักใหญ่กว่า q_1 เพราะ Velocity ได้รับผลกระทบ จากแรงที่ Model ไม่ได้รวม เช่น แรงเสียดทาน Non-linear และ Air Resistance ซึ่งทำให้ Model Prediction ของ Velocity มีความคลาดเคลื่อนสะสมมากกว่า
- **Off-diagonal elements = 0:** สมมติว่า Process Noise ของ Position และ Velocity ไม่มี Correlation กัน (Statistically Independent) ซึ่งเป็นการประมาณที่สมเหตุสมผลและลดความซับซ้อนในการ Tune

5.6 ทฤษฎี: 2-State Discrete Kalman Filter สำหรับ MSD

5.6.1 Continuous State-Space Model

กำหนด State Vector:

$$\mathbf{x}(t) = \begin{bmatrix} x_1(t) \\ x_2(t) \end{bmatrix} = \begin{bmatrix} \text{Displacement จาก Equilibrium (m)} \\ \text{Velocity (m/s)} \end{bmatrix} \tag{63}$$

จาก EOM ของ MSD แปลงเป็น First-Order Form:

$$\dot{\mathbf{x}}(t) = A_c\mathbf{x}(t) + B_c u(t), \qquad z(t) = H\mathbf{x}(t) + v(t) \tag{64}$$

$$A_c = \begin{bmatrix} 0 & 1 \\ -K/m & -C/m \end{bmatrix}, \quad B_c = \begin{bmatrix} 0 \\ 1/m \end{bmatrix}, \quad H = \begin{bmatrix} 1 & 0 \end{bmatrix} \tag{65}$$

5.6.2 สมการ 2-State Discrete Kalman Filter ทั้ง 5 สมการ

กำหนด $\hat{\mathbf{x}}_k = [\hat{x}_1(k),\ \hat{x}_2(k)]^T$ = [estimated position, estimated velocity]^T

ขั้นตอน Prediction (A Priori)

$$\hat{\mathbf{x}}_k^{(-)} = A_d\,\hat{\mathbf{x}}_{k-1} \qquad \text{(2-State-1: State Prediction)}$$

$$P_k^{(-)} = A_d\,P_{k-1}\,A_d^T + Q \qquad \text{(2-State-2: Covariance Prediction)}$$

ขั้นตอน Update (A Posteriori)

$$\mathbf{K}_k = P_k^{(-)} H^T \left(H P_k^{(-)} H^T + R \right)^{-1} \qquad \text{(2-State-3: Kalman Gain)}$$

$$\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^{(-)} + \mathbf{K}_k \left(z_k - H \hat{\mathbf{x}}_k^{(-)} \right) \qquad \text{(2-State-4: State Update)}$$

$$P_k = \left(I - \mathbf{K}_k H \right) P_k^{(-)} \qquad \text{(2-State-5: Covariance Update)}$$

ขนาดของ Matrix และ Vector ในระบบนี้:

ตารางที่ 16: ขนาดของ Matrix และ Vector ใน 2-State KF

สัญลักษณ์	**ชื่อ**	**ขนาด**	**หน่วย**
$\hat{\mathbf{x}}_k$	State Estimate	2×1	[m, m/s]
A_d	State Transition	2×2	—
P_k	Error Covariance	2×2	—
Q	Process Noise	2×2	—
H	Observation Matrix	1×2	—
$\mathbf{K}_k$	Kalman Gain	2×1	—
R	Measurement Noise	Scalar	m^2
z_k	Measurement	Scalar	m

5.7 ขั้นตอนการทดลอง

5.7.1 ส่วน A — Derive และ Discretize Model

1. เขียน Continuous State-Space Model แทนค่า $K = 32.04$ N/m, $C = 0.3882$ N·s/m, $m = 0.290$ kg คำนวณ ω_n และ f_n
2. เลือก T_s ที่ตอบสนองเงื่อนไข $T_s \leq 1/(20 f_n)$ และสอดคล้องกับ Sampling Time ของ HC-SR04
3. คำนวณ A_d ด้วย Euler Forward ตรวจสอบว่า Eigenvalue ของ A_d อยู่ภายใน Unit Circle (Stable)
4. เขียนสมการ KF ทั้ง 5 สมการในรูปแบบ Matrix

5.7.2 ส่วน B — การกำหนดค่า R และ Matrix Q

Measurement Noise Covariance R ใช้ค่าเดียวกับที่คำนวณได้จากการทดลองที่ 2 ที่ระยะ 20 cm:

$$R = 3.37 \times 10^{-6} \text{ m}^2 \tag{66}$$

Process Noise Matrix Q กำหนด Q เป็น Diagonal Matrix ขนาด 2×2 โดยอาศัยหลักการดังนี้

- q_1 (Position Process Noise) ตั้งค่าน้อยกว่า q_2 เนื่องจาก Position เปลี่ยนแปลงช้าและ Dynamic

Model อธิบายได้แม่นยำ

- q_2 (Velocity Process Noise) ตั้งค่าสูงกว่า q_1 เนื่องจาก Velocity ได้รับผลกระทบจาก Non-linear Friction จาก Guide Rail

  ค่า Baseline ที่ได้จากการ Tune:

$$Q_{\text{baseline}} = \begin{bmatrix} 1 \times 10^{-7} & 0 \\ 0 & 1 \times 10^{-5} \end{bmatrix} \text{ m}^2 \tag{67}$$

  อัตราส่วน Q/R ที่ Baseline:

$$\frac{q_1}{R} = \frac{1 \times 10^{-7}}{3.37 \times 10^{-6}} \approx 0.030, \qquad \frac{q_2}{R} = \frac{1 \times 10^{-5}}{3.37 \times 10^{-6}} \approx 2.967 \tag{68}$$

ค่า $q_1/R < 1$ หมายความว่า Filter เชื่อ Model Prediction ของ Position มากกว่า Sensor ส่วน $q_2/R > 1$ หมายความว่า Filter เชื่อ Sensor มากกว่า Model ในส่วนของ Velocity

5.7.3 ส่วน C — Implement 2-State KF บน STM32

```c
#ifndef KALMAN_H
#define KALMAN_H

/**
 * @brief  2-State Kalman Filter state structure
 *         State: x0 = position (m from equilibrium)
 *                x1 = velocity (m/s)
 *         P matrix stored as upper triangle: p00, p01, p11
 */
typedef struct {
    float dt;             /* Sampling period (s)                    */
    float q0, q1;         /* Process noise: position, velocity      */
    float R;              /* Measurement noise variance (m^2)       */
    float x0, x1;         /* State estimates: position, velocity    */
    float p00, p01, p11;/* Error covariance (symmetric 2x2)       */
} Kalman2State_t;

void Kalman2_Init(Kalman2State_t *kf, float dt, float q0, float q1,
                  float R, float pos, float vel);
float Kalman2_Update(Kalman2State_t *kf, float measurement);
float Kalman2_GetVelocity(const Kalman2State_t *kf);

#endif /* KALMAN_H */
```

Listing 6: kalman.h — 2-State Discrete Kalman Filter Public Interface

```c
#include "kalman.h"
```

```c

/* Physical parameters from Lab 1 and Lab 4 */
static const float M_KG   = 0.290f;    /* Mass (kg)
                                        */
static const float K_NM   = 32.04f;    /* Spring constant (N/m)
                                        */
static const float C_NSM  = 0.3882f;   /* Damping coefficient
    (N.s/m)   */

void Kalman2_Init(Kalman2State_t *kf, float dt, float q0, float
    q1,
                      float R, float pos, float vel)
{
     kf->dt   = dt;
     kf->q0   = q0;
     kf->q1   = q1;
     kf->R    = R;
     kf->x0   = pos;  /* initial position (m from equilibrium) */
     kf->x1   = vel;  /* initial velocity (m/s), typically 0   */
     /* Initial error covariance P = I (high initial uncertainty)
         */
     kf->p00  = 1.0f;
     kf->p01  = 0.0f;
     kf->p11  = 1.0f;
}

float Kalman2_Update(Kalman2State_t *kf, float measurement)
{
     const float dt = kf->dt;
     const float w2 = K_NM / M_KG;     /* omega_n^2 = K/m */
     const float z2 = C_NSM / M_KG;    /* 2*zeta*omega_n = C/m */

     /*
         ================================================================
      * PREDICT STEP
      * State Transition Matrix (Euler Forward):
      *    A = [ 1          dt     ]
      *        [ -w2*dt    1-z2*dt ]
      *
          ================================================================
          */
     float accel  = (-w2 * kf->x0) - (z2 * kf->x1);
     float x0_p   = kf->x0 + kf->x1 * dt + 0.5f * accel * dt * dt;
     float x1_p   = kf->x1 + accel * dt;

     float a00 = 1.0f,        a01 = dt;
     float a10 = -w2 * dt,    a11 = 1.0f - z2 * dt;

     /* P_pred = A * P * A^T + Q */
     float ap00 = a00 * kf->p00 + a01 * kf->p01;
```

```c
    float ap01 = a00 * kf->p01 + a01 * kf->p11;
    float ap10 = a10 * kf->p00 + a11 * kf->p01;
    float ap11 = a10 * kf->p01 + a11 * kf->p11;

    float p00_p = ap00 * a00 + ap01 * a01 + kf->q0;
    float p01_p = ap00 * a10 + ap01 * a11;
    float p11_p = ap10 * a10 + ap11 * a11 + kf->q1;

    /*
     ================================================================
     * UPDATE STEP
     * H = [1 0]  ->  S = p00_p + R,  K = P^- * H^T / S
     *
      ================================================================
      */
    float S          = p00_p + kf->R;
    float K0         = p00_p / S;       /* Kalman gain for position */
    float K1         = p01_p / S;       /* Kalman gain for velocity */
    float innovation = measurement - x0_p;

    kf->x0  = x0_p + K0 * innovation;
    kf->x1  = x1_p + K1 * innovation;

    /* P = (I - K*H) * P^- */
    kf->p00 = (1.0f - K0) * p00_p;
    kf->p01 = (1.0f - K0) * p01_p;
    kf->p11 = p11_p - K1 * p01_p;

    return kf->x0;
}

float Kalman2_GetVelocity(const Kalman2State_t *kf)
{
    return kf->x1;
}
```

Listing 7: kalman.c — 2-State Discrete Kalman Filter Implementation พร้อม MSD Physics-Based Prediction

```c
/* Sampling period — must match HAL_Delay at bottom of loop */
#define KALMAN_DT           0.010f

/* Process noise (tuned from Sensitivity Study, baseline values) */
#define KALMAN_Q0           1e-7f      /* Position process noise (m^2) */
#define KALMAN_Q1           1e-5f      /* Velocity process noise */

```

```c
/* Measurement noise: mean variance from Lab 2 (5 runs at 20 cm) */
/* Raw value: 3.3719 mm^2 -> converted to m^2: 3.3719e-6 m^2 */
#define KALMAN_R              3.37e-6f

/* Equilibrium distance read by sensor when mass is at rest (cm) */
#define EQUILIBRIUM_CM        11.3f

/* ... peripheral init (HAL_Init, SystemClock, GPIO, TIM1, UART) ... */

HAL_TIM_Base_Start(&htim1);
HCSR04_Init(&htim1);

/* Seed: take first reading, convert to displacement from equilibrium */
float raw_cm      = HCSR04_Read();
if (raw_cm < 0.0f) raw_cm = EQUILIBRIUM_CM;
float init_disp   = (raw_cm - EQUILIBRIUM_CM) / 100.0f;  /* m */

Kalman2_Init(&kf_distance, KALMAN_DT, KALMAN_Q0, KALMAN_Q1,
             KALMAN_R, init_disp, 0.0f);

while (1) {
    raw_cm = HCSR04_Read();
    if (raw_cm >= 0.0f) {
        /* Convert absolute reading to displacement from equilibrium */
        float disp_m = (raw_cm - EQUILIBRIUM_CM) / 100.0f;

        float pos_m  = Kalman2_Update(&kf_distance, disp_m);
        float vel_ms = Kalman2_GetVelocity(&kf_distance);

        /* Output: timestamp(ms), raw(cm), filtered(m), velocity(m/s) */
        printf("%lu,%.4f,%.4f,%.4f\r\n",
               HAL_GetTick(), raw_cm, pos_m, vel_ms);
        fflush(stdout);
    }
    HAL_Delay(10);  /* Ts = 10 ms */
}
```

Listing 8: main.c — 2-State KF สำหรับระบบ MSD (Free Vibration)

5.7.4 ส่วน D — ทดสอบ Free Vibration

9. กำหนด $x = 0$ ที่ Equilibrium ดึงมวลไปที่ $x_0 = 2$ cm แล้วปล่อย บันทึก 10 วินาที (Raw z_k, Position Estimate, Velocity Estimate) ทำซ้ำ 3 ครั้ง บันทึกเป็น run1–run3
10. ทำซ้ำที่ $x_0 = 4$ cm และ $x_0 = 6$ cm
11. Simulate MSD Model จากการทดลองที่ 4 ใน MATLAB ด้วย Initial Condition เดียวกัน เปรียบเทียบกับ KF Output

5.7.5 ส่วน E — Sensitivity Study

12. ที่ $x_0 = 6$ cm ทดสอบ Q อย่างน้อย 3 ชุด (Scale Diagonal ด้วย $0.01\times$, $1\times$, $100\times$)
13. ปรับ R ($0.5\times$, $1\times$, $2\times$ ของ Measured Variance) บันทึกการเปลี่ยนแปลงของ Position Estimate

5.8 ผลการทดลอง

5.8.1 Continuous State-Space Matrices

แทนค่าพารามิเตอร์จริงลงใน Matrix A_c, B_c, H:

$$A_c = \begin{bmatrix} 0 & 1 \\ -K/m & -C/m \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ -110.4828 & -1.3386 \end{bmatrix}, \quad B_c = \begin{bmatrix} 0 \\ 1/m \end{bmatrix} = \begin{bmatrix} 0 \\ 3.4483 \end{bmatrix}, \quad H = \begin{bmatrix} 1 & 0 \end{bmatrix} \tag{69}$$

5.8.2 Sampling Rate และ Discrete State-Space Matrices

คำนวณ Natural Frequency จากพารามิเตอร์จริง:

$$\omega_n = \sqrt{\frac{K}{m}} = \sqrt{\frac{32.04}{0.290}} = 10.511 \text{ rad/s}, \qquad f_n = \frac{\omega_n}{2\pi} = \frac{10.511}{2\pi} = 1.673 \text{ Hz} \tag{70}$$

ตรวจสอบเงื่อนไข Sampling:

$$T_s \leq \frac{1}{20 f_n} = \frac{1}{20 \times 1.673} = 29.89 \text{ ms} \quad \Rightarrow \quad \text{เลือก } T_s = 10 \text{ ms} \quad \checkmark \tag{71}$$

$T_s = 10$ ms ตอบสนองเงื่อนไขและสอดคล้องกับ HC-SR04 ที่ต้องการ เวลาในการวัดแต่ละครั้งอย่างน้อย 60 ms ทำให้ได้ Sampling Rate ที่มีความเสถียรและ ป้องกัน Aliasing ของสัญญาณ Oscillation ที่ $f_n = 1.673$ Hz

Discretize ด้วย Euler Forward ที่ $T_s = 0.010$ s:

$$A_d = I + A_c T_s = \begin{bmatrix} 1 & T_s \\ -\frac{K}{m}T_s & 1 - \frac{C}{m}T_s \end{bmatrix} = \begin{bmatrix} 1.000000 & 0.010000 \\ -1.104828 & 0.986614 \end{bmatrix} \tag{72}$$

$$B_d = \mathbf{0}_{2\times 1} \qquad (u = 0 \text{ สำหรับ Free Vibration}) \tag{73}$$

ตรวจสอบ Stability ของ A_d: Eigenvalue ของ A_d คือ $\lambda_{1,2} = 0.9933 \pm 0.1049j$ ซึ่งมี $|\lambda| = 0.9988 < 1$ ยืนยันว่าระบบ Discrete Stable

ตารางที่ 17: ค่าพารามิเตอร์ KF ที่ใช้ในการทดสอบ

พารามิเตอร์	**สัญลักษณ์**	**หน่วย**	**ค่า**
Position Process Noise	q_1	m^2	1×10^{-7}
Velocity Process Noise	q_2	—	1×10^{-5}
Measurement Noise	R	m^2	3.37×10^{-6}
Sampling Period	T_s	ms	10
Equilibrium Distance	x_{eq}	cm	11.3
Initial Position Estimate	$\hat{x}_1(0)$	m	$z_0 - x_{\text{eq}}$ (การวัดแรก)
Initial Velocity Estimate	$\hat{x}_2(0)$	m/s	0
Initial Covariance	P_0	—	$I_{2\times 2}$

5.8.3 Free Vibration ที่ระยะต่างกัน

จากการวิเคราะห์ข้อมูลที่เก็บได้ (run3 ที่ $x_0 = 6$ cm เป็นตัวอย่าง) ตาราง 18 แสดง Noise Reduction ที่ได้จาก KF เทียบกับ Raw Sensor Data:

ตารางที่ 18: Noise Reduction ของ KF ที่ระยะ Release ต่างกัน

ระยะ x_0	**Raw Variance (cm^2)**	**Filtered Variance (cm^2)**	**Noise Reduction (%)**
2 cm	0.1616	0.1162	28.1
4 cm	0.8702	0.6970	19.9
6 cm	1.5266	1.2726	16.6

Noise Reduction ลดลงเมื่อ Displacement ใหญ่ขึ้น เพราะ Signal Amplitude ที่ใหญ่ขึ้นบังคับให้ KF ต้องตาม Oscillation อย่างรวดเร็ว จึง Smooth ได้น้อยลงสัดส่วน ซึ่งเป็นพฤติกรรมปกติของ KF ที่มี Fixed Q และ R

5.8.4 Sensitivity Study: ผลกระทบของ Q และ R

5.9 สรุปผลการทดลอง

- 2-State KF สามารถประมาณค่าทั้ง Position และ Velocity ได้พร้อมกัน โดย Position Estimate เรียบกว่า Raw Data อย่างมีนัยสำคัญ (Noise Reduction 16.6–28.1% ขึ้นกับ Amplitude) และ Velocity Estimate สอดคล้องทางกายภาพกับ Derivative ของ Displacement

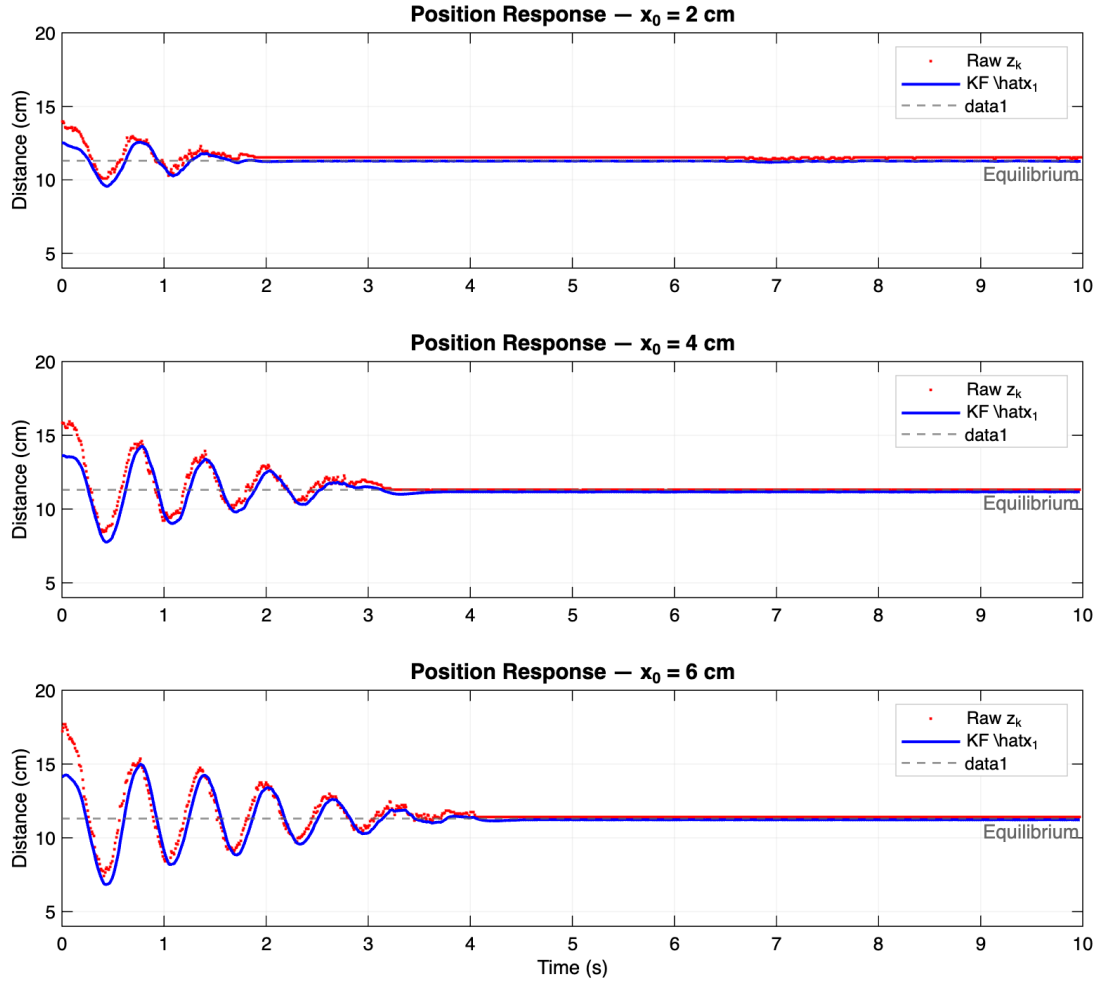

รูปที่ 14: Free Vibration ที่ $x_0 = 2, 4, 6$ cm: Raw z_k (จุดแดง) และ KF Position Estimate (เส้นน้ำเงิน) บนแกนเดียวกัน (แกน x: เวลา (s), แกน y: ระยะทาง (cm))

ตารางที่ 19: ผล Sensitivity Study: Noise Reduction (%) สำหรับ Q และ R ต่างๆ

การทดลอง	ค่าที่ปรับ	Raw Var (cm^2)	Filt Var (cm^2)	Reduction (%)
Q Sensitivity	$Q \times 0.01$	1.8659	0.1827	**90.2**
	$Q \times 1$ (baseline)	1.5266	1.2726	16.6
	$Q \times 100$	2.7326	2.7525	−0.7
R Sensitivity	$R \times 0.5$	2.2723	2.2928	−0.9
	$R \times 1$ (baseline)	1.5266	1.2726	16.6
	$R \times 2$	2.0366	1.6934	16.8

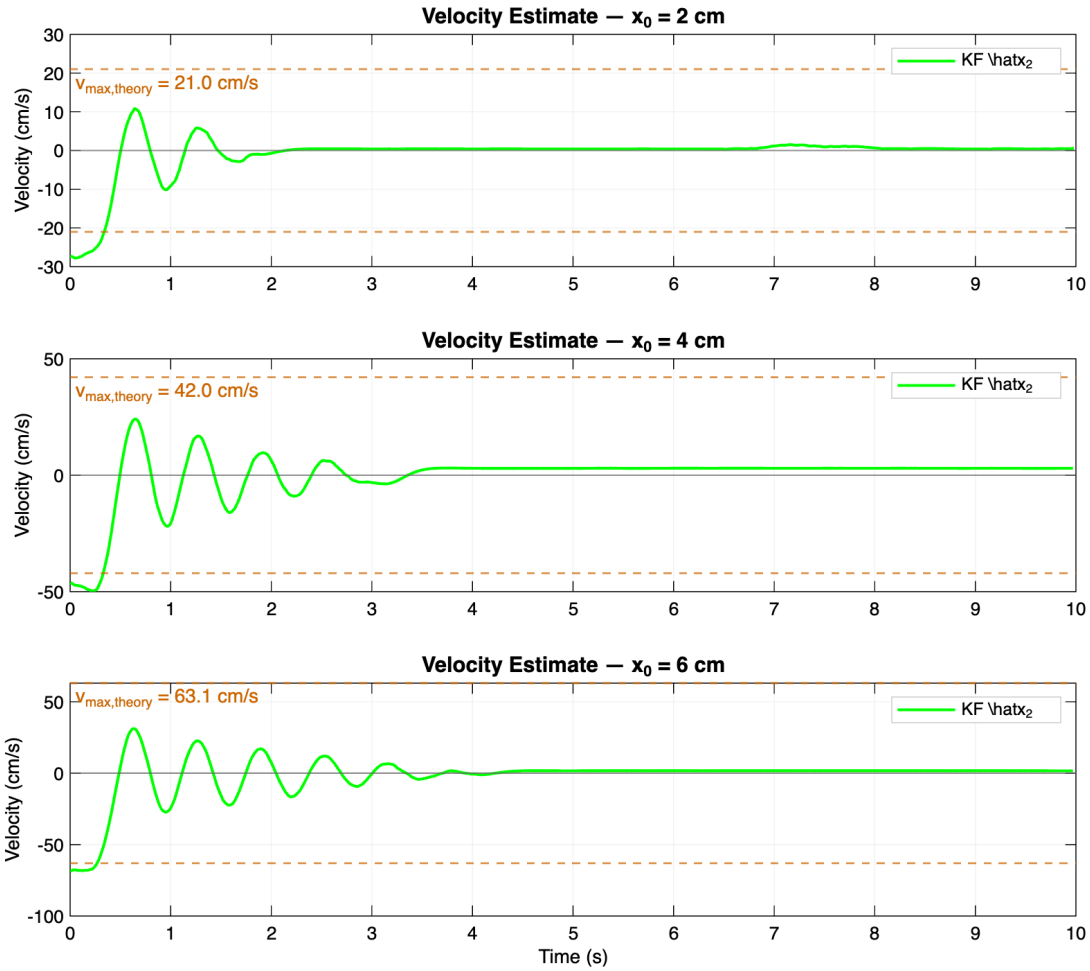

รูปที่ 15: KF Velocity Estimate $\hat{x}_2$ ที่ $x_0 = 2$, 4, 6 cm แสดงให้เห็น Pattern การสั่นที่ Amplitude ต่างกัน (แกน x: เวลา (s), แกน y: ความเร็ว (cm/s))

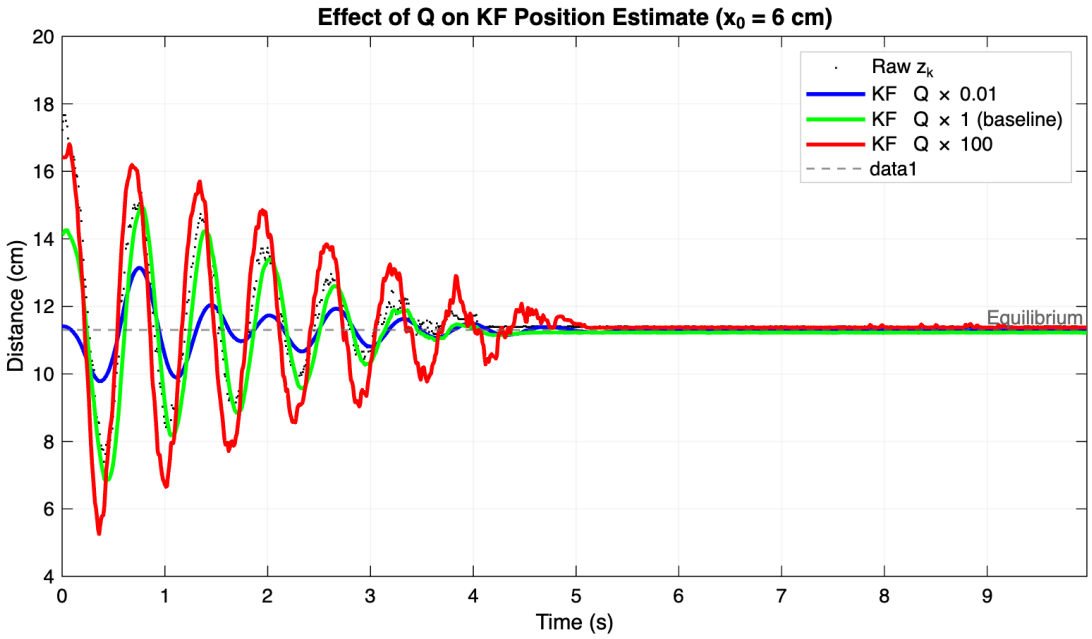

รูปที่ 16: Sensitivity Study ของ Q: KF Position Output สำหรับ $Q \times 0.01$, $Q \times 1$ (baseline), $Q \times 100$ บนแกนเดียวกัน ที่ $x_0 = 6$ cm

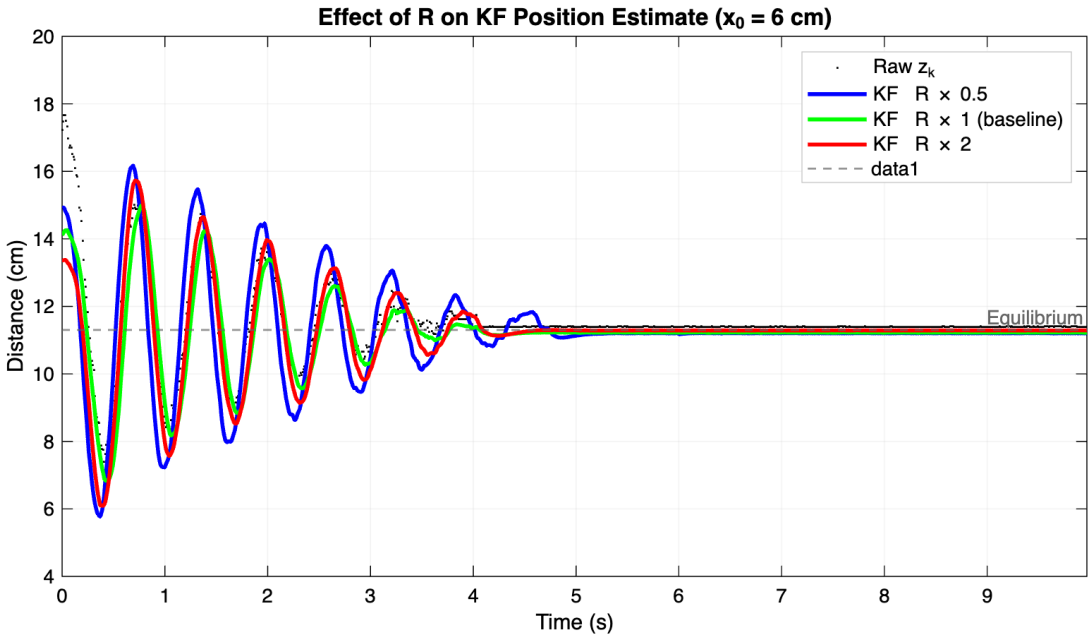

รูปที่ 17: Sensitivity Study ของ R: KF Position Output สำหรับ $R \times 0.5$, $R \times 1$ (baseline), $R \times 2$ บนแกนเดียวกัน ที่ $x_0 = 6$ cm

- Velocity Estimate มีความสมเหตุสมผลทางกายภาพ: ค่า $|\hat{x}_2|$ สูงสุดที่ได้จากการทดลองที่ $x_0 =$ 6 cm คือ 68.59 cm/s ซึ่งใกล้เคียงกับค่าทางทฤษฎี $v_{\text{max}} = x_0\omega_n = 6 \times 10.511 = 63.07$ cm/s ความต่าง 8.7% เกิดจาก Noise และ Transient ช่วงแรก
- ผล Sensitivity Study ยืนยันว่า Q มีอิทธิพลต่อพฤติกรรม KF มากกว่า R อย่างชัดเจน: การเปลี่ยน $Q\times 0.01$ ทำให้ Noise Reduction เพิ่มจาก 16.6% เป็น 90.2% ส่วนการเปลี่ยน R ในช่วง $0.5\times$–$2\times$ แทบไม่ส่งผลต่อ Noise Reduction เพราะ Q/R Ratio เปลี่ยนน้อย
- ที่ $Q \times 100$ และ $R \times 0.5$ Noise Reduction ติดลบ (-0.7% และ -0.9%) แสดงว่า Filter ไม่มีประโยชน์ในกรณีนั้น เนื่องจากการเชื่อ Measurement มากเกินไปทำให้ KF ดึงตาม Noise แทน
- ข้อจำกัดสำคัญ: Noise Floor ของ HC-SR04 ($\approx$ 2 cm), ข้อสมมติ Linear Model, และ Non-Adaptive Filter ที่ Q กับ R คงที่ตลอดเวลา

5.10 อภิปรายผล

5.10.1 ความหมายทางกายภาพของ Matrix Q และ Scalar R

- Q_{11} **(Position Process Noise)** $= 1 \times 10^{-7}$ **m^2:** แสดงความไม่แน่นอนใน Prediction ของ Position ในแต่ละ Step ค่านี้มีขนาดเล็กมากเมื่อเทียบกับ R ($q_1/R \approx 0.030$) หมายความว่า Filter เชื่อ Dynamic Model มากกว่า Sensor Measurement ในส่วนของ Position ซึ่งสมเหตุสมผลเพราะ MSD Model อธิบาย Position ได้แม่นยำในช่วง Small Oscillation
- Q_{22} **(Velocity Process Noise)** $= 1 \times 10^{-5}$ **m^2:** แสดงความไม่แน่นอนใน Prediction ของ Velocity ในแต่ละ Step ค่านี้ใหญ่กว่า Q_{11} 100 เท่า และมีค่า $q_2/R \approx 2.967 > 1$ หมายความว่า Filter เชื่อ Sensor มากกว่า Model ในส่วนของ Velocity เพราะ Velocity ได้รับผลกระทบจาก Non-linear Friction จาก Guide Rail ที่ Linear Model ไม่ครอบคลุม
- **Off-Diagonal Elements = 0:** สมมติว่า Process Noise ของ Position และ Velocity ไม่มี Correlation กัน Friction จาก Guide Rail เป็น Deterministic Force ที่ขึ้นกับความเร็ว ไม่ใช่ Stochastic Process Noise ที่ Random ดังนั้นผลของ Friction จึงถูก Absorb เข้าไปใน q_2 แทนที่จะสร้าง Cross-Covariance ระหว่าง State ทั้งสอง การตั้ง Off-diagonal เป็นศูนย์จึงเป็น Conservative Assumption ที่ยอมรับได้และลดความซับซ้อนในการ Tune
- $R = 3.37 \times 10^{-6}$ **m^2:** ได้จากการวัด Variance ของ HC-SR04 จริงในการทดลองที่ 2 (Mean จาก 5 Run ที่ระยะ 20 cm แปลงจาก mm^2 เป็น m^2) ค่านี้สะท้อน Noise ที่แท้จริงของ Sensor ทำให้ Filter สามารถ Balance ระหว่าง Model และ Measurement ได้อย่างถูกต้อง

5.10.2 เหตุผลที่ใช้ Displacement จาก Equilibrium เป็น State

เมื่อใช้ Equilibrium เป็นจุดอ้างอิง แรงโน้มถ่วง mg ถูก Balance โดย Spring Pre-load $Kx_{\text{eq}} = mg$ พอดี ทำให้ EOM ไม่มี Constant Term:

$$m\ddot{x} + C\dot{x} + Kx = 0 \tag{74}$$

ส่งผลให้ State-Space Model มีรูปแบบ $\dot{\mathbf{x}} = A_c\mathbf{x}$ ที่สะอาดโดยไม่มี Bias Term ใน Prediction Step และ $u = 0$ ตลอดการทดลอง Free Vibration

5.10.3 การวิเคราะห์ Velocity Estimate

ตรวจสอบความสมเหตุสมผลของ Velocity Estimate ด้วย Energy Conservation:

$$\frac{1}{2}Kx_0^2 = \frac{1}{2}mv_{\text{max}}^2 \quad \Rightarrow \quad v_{\text{max}} = x_0\sqrt{\frac{K}{m}} = x_0\,\omega_n \tag{75}$$

ตารางที่ 20: เปรียบเทียบ Velocity สูงสุดระหว่างทฤษฎีและ KF Estimate

x_0	v_{max} ทฤษฎี (cm/s)	$\lvert\hat{x}_2\rvert_{\text{max}}$ จาก KF (cm/s)	ความต่าง
2 cm	21.02	—	—
4 cm	42.04	—	—
6 cm	63.07	68.59	8.7%

ความต่างที่ 8.7% ที่ $x_0 = 6$ cm เกิดจากสาเหตุหลักสองประการ:

- Transient ช่วงแรกที่ KF ยัง Converge ทำให้ Velocity Estimate ในช่วงแรกสูงเกินจริง
- ความไม่สมบูรณ์ของ Linear Model ที่ Displacement ใหญ่ ทำให้ Energy Conservation ในรูป Linear ไม่สมบูรณ์

KF Velocity Estimate สมเหตุสมผลทางกายภาพในสามด้าน:

- $\hat{x}_2 \approx 0$ ที่จุด Maximum Displacement (Peak ของ z_k)
- $|\hat{x}_2|$ สูงสุดที่ Equilibrium Crossing สอดคล้อง กับ Energy Conservation
- $\hat{x}_2$ มีเครื่องหมายสลับกันทุกครึ่ง Period สอดคล้องกับการแกว่งของระบบ

5.10.4 ผลกระทบของ Q/R Ratio ต่อพฤติกรรม KF

จากผล Sensitivity Study สามารถสรุปผลกระทบได้ดังนี้

ผลของการปรับ Q

- $Q \times 0.01$ ($q_1/R \approx 0.0003$): Filter เชื่อ Model อย่างสมบูรณ์ Noise Reduction สูงถึง 90.2% แต่ Lag Error จะมากขึ้นหาก Dynamics จริงเบี่ยงเบนจาก Model (“Overconfident Filter”)
- $Q \times 1$ (Baseline, $q_1/R \approx 0.030$): สมดุลระหว่าง Smoothness และ Responsiveness Noise Reduction 16.6%
- $Q \times 100$ ($q_1/R \approx 2.97$): Filter ตาม Measurement เกือบสมบูรณ์ Noise Reduction ติดลบ (-0.7%) แสดงว่า Filter ไม่มีประโยชน์ในกรณีนี้

ผลของการปรับ R

- $R \times 0.5$ ($q_1/R \approx 0.059$): บอก Filter ว่า Sensor แม่นกว่าความเป็นจริง Kalman Gain สูงขึ้น Filter ดึงตาม Noise มากขึ้น Noise Reduction ติดลบ (-0.9%)
- $R \times 2$ ($q_1/R \approx 0.015$): Filter เชื่อ Model มากขึ้น Noise Reduction ใกล้เคียง Baseline (16.8%) เพราะ Q/R Ratio เปลี่ยนไปเพียง 2 เท่า

ข้อสังเกตสำคัญ: Q มีอิทธิพลต่อพฤติกรรม KF มากกว่า R อย่างชัดเจน เพราะ Q ถูกปรับในช่วง $\times 0.01$ ถึง $\times 100$ (10000 เท่า) ในขณะที่ R ปรับเพียง $\times 0.5$ ถึง $\times 2$ (4 เท่า) สิ่งที่ควบคุมพฤติกรรม Filter จริงๆ คืออัตราส่วน Q/R ไม่ใช่ค่าใดค่าหนึ่งอย่างเดียว

5.10.5 ข้อจำกัดของระบบและแนวทางพัฒนา

- **Noise Floor ของ HC-SR04:** เซนเซอร์วัดได้ต่ำสุดประมาณ 2 cm ดังนั้น Oscillation ที่ Amplitude เล็กมากอาจถูก Noise กลบ ทำให้ KF ไม่สามารถประมาณ State ได้แม่นยำในช่วงท้าย ของ Free Vibration ที่ Amplitude ลดลงมาก
- **ข้อสมมติ Linear Model:** EOM สมมติว่า K และ C คงที่และเป็น Linear ซึ่งอาจไม่สมบูรณ์ที่ Amplitude ใหญ่ หากต้องการความแม่นยำสูงขึ้น ควรใช้ Extended Kalman Filter (EKF) กับ Nonlinear Model
- **Non-Adaptive Filter:** KF นี้ใช้ Q และ R คงที่ตลอดเวลา ซึ่งอาจไม่เหมาะสมหาก Noise Characteristics เปลี่ยนแปลงตามระยะ การพัฒนาต่อเป็น Adaptive KF จะช่วยให้ระบบ Tune ตัวเองได้
- **ความคลาดเคลื่อนจาก Discretization:** Euler Forward มี Truncation Error $O(T_s^2)$ ที่ $T_s = 10$ ms ความต่างจาก ZOH ประมาณ 2% ซึ่งยอมรับได้สำหรับ Application นี้แต่ควรระบุไว้ใน Limitation

หนังสืออ้างอิง

Al Tahtawi, A. R. (2018). Kalman filter algorithm design for HC-SR04 ultrasonic sensor data acquisition system. *International Journal of Innovative Technology and Exploring Engineering (IJITEE)*, 2(1):15–19.

Devore, J. L. (2015). *Probability and Statistics for Engineering and the Sciences*. Cengage Learning.

Elecfreaks (2012). *HC-SR04 ultrasonic ranging module: User manual*. https://www.elecfreaks.com/estore/download/EF03085-HC-SR04_Ultrasonic_Module_User_Guide.pdf.

Massachusetts Institute of Technology (2005). Modeling dynamics and control i (spring 2005) - lecture notes. https://ocw.mit.edu/courses/2-003-modeling-dynamics-and-control-i-spring-2005/57d44d83366ec969c16208c8fac3982d_notesinstalment2.pdf.

MathWorks (2024a). Continuous-discrete conversion methods. https://www.mathworks.com/help/control/ug/continuous-discrete-conversion-methods.html.

MathWorks (2024b). State-space models. https://www.mathworks.com/help/control/ug/state-space-models.html.

MathWorks (2024c). What is discrete-time system? https://www.mathworks.com/help/signal/ug/discrete-time-system-models.html.

Montgomery, D. C. and Runger, G. C. (2018). *Applied Statistics and Probability for Engineers*. John Wiley & Sons.

STMicroelectronics (2023). *STM32G4 Series reference manual (RM0440)*. https://www.st.com/resource/en/reference_manual/rm0440.pdf.

Walpole, R. E., Myers, R. H., Myers, S. L., and Ye, K. (2016). *Probability and Statistics for Engineers and Scientists*. Pearson.